1. Programación multiproceso y paralela.

El uso de **varios procesadores** dentro de un sistema informático se nombra **multiproceso**.

1.1 Programación multiproceso.

1.1.1 Proceso, sistemas monoprocesador y multiprocesador.

Un **programa** es un elemento estático, un conjunto de instrucciones, unas líneas de código escritas en un lenguaje de programación, que describen el tratamiento que hay que dar a unos datos iniciales (de entrada) por conseguir el resultado esperado (una salida concreta).

En cambio, un **proceso** es dinámico, es una instancia de un **programa en ejecución**, que realiza los cambios indicados por el programa a las datos iniciales y obtiene una salida concreta. El proceso, además de las instrucciones, requerirá también de recursos específicos para la ejecución como el contador de instrucciones del programa, el contenido de los registros o los datos.

El **sistema operativo** es el encargado de la gestión de procesos.

P1 P2 P3

Sistema operatiu

Editor de text

FIGURA 1.1. Execució de processos

Cuando se ejecuta un programa, el sistema operativo crea una instancia del programa: el proceso.

El elemento de hardware en el que se ejecutan los procesos es el **procesador**.

Un procesador es el componente de hardware de un sistema informático encargado de ejecutar las instrucciones y procesar los datos.

Un sistema **monoprocesador** es aquel que está formado únicamente por un procesador.

Un sistema **multiprocesador** está formado por más de un procesador.

Actualmente, la mayoría de los sistemas operativos aprovechan los tiempos de reposo de los procesos, cuando esperan, por introducir al procesador otro proceso, **simulando así una ejecución paralela**.

De forma genérica llamaremos a los procesos que se ejecutan a la vez, ya sea de forma real o simulada, **procesos concurrentes**.

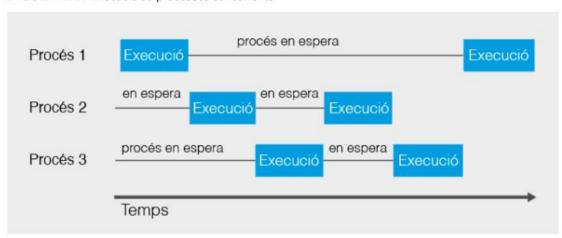


FIGURA 1.2. Execució de processos concurrents

Es el sistema operativo el encargado de gestionar la ejecución concurrente de diferentes procesos contra un mismo procesador y a menudo nos referimos con el nombre de **multiprogramación**.

Hablamos de multiprogramación cuando el sistema operativo gestiona la ejecución de procesos concurrentes a un sistema monoprocesador.

El sistema operativo Windows 95 únicamente permite trabajar con un único procesador. Los sistemas operativos a partir de Win2000/NT y Linux/Unix son multiproceso, pueden trabajar con más de un procesador.

En un sistema informático multiprocesador existen dos o más procesadores, por tanto se pueden ejecutar simultáneamente varios procesos. También se pueden calificar de multiprocesadores aquellos dispositivos cuyo procesador tiene más de un núcleo (multicore), es decir, tienen más de una CPU al mismo circuito integrado del procesador.

Sistemas multiprocesadores fuertemente acoplados: en esta arquitectura los diferentes procesadores comparten una misma memoria y están interconectados a ella a través de un bus.

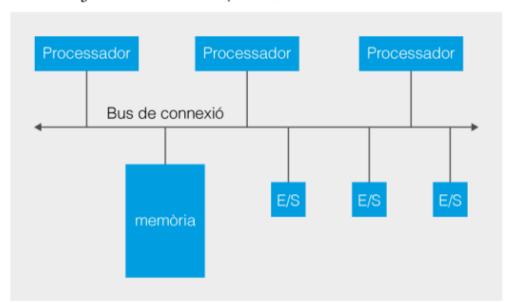


FIGURA 1.3. Sistema informàtic multiprocessador fortament acoblat

Se pueden dividir en **sistemas multiproceso simétricos**, en los que los procesadores del sistema son de características similares y compiten entre iguales por ejecutar procesos, y **sistemas multiproceso asimétricos** en los cuales uno de los procesadores del sistema, el máster, controla la resto de procesadores. Este sistema también se llama master-slave.

Sistemas multiprocesadores débilmente acoplados: estos sistemas no comparten memoria, cada procesador tiene una memoria asociada.

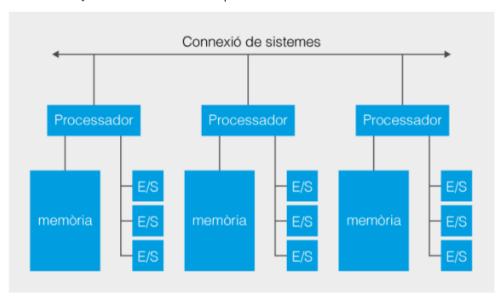


FIGURA 1.4. Sistema informàtic multiprocessador dèbilment acoblat

Un tipo de estos sistemas poco acoplados son los **sistemas distribuidos**, en los que cada dispositivo monoprocesador (o multiprocesador) podría estar situado en lugares físicamente distantes.

1.1.2 Programación concurrente, paralela y distribuida.

La ejecución simultánea de procesos se llama también concurrencia.

No quiere decir que se hayan de ejecutar exactamente al mismo momento, el intercalado de procesos también se considera ejecución concurrente.

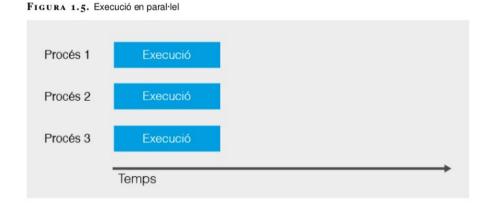
Hablamos de **programación concurrente** cuando se ejecutan en un dispositivo informático de forma simultánea diferentes tareas (procesos).

La ejecución concurrente puede comportar ciertos problemas a la hora de acceder a las datos. Básicamente usaremos dos técnicas por evitarlos: el boqueo y la comunicación.

Si la programación concurrente se da en un computador con un único procesador hablaremos de multiprogramación. En cambio, si el computador tiene más de un procesador y, por tanto, los procesos se pueden ejecutar de forma realmente simultánea, hablaremos de programación paralela.

En un dispositivo multiprocesador la concurrencia es real, los procesos son ejecutados de forma simultánea en diferentes procesadores del sistema.

Cuando la programación concurrente se realiza en un sistema multiprocesador hablamos de **programación paralela**.



El principal desventaja de la programación paralela son los controles que debemos añadir para que la **comunicación y sincronización** de los procesos que se ejecutan concurrentemente sean correctos.

El lenguaje de programación Java tiene integrado el apoyo a la concurrencia en el propio lenguaje y no a través de librerías.

Un tipo especial de programación paralela es la renombrada **programación distribuida**. Esta programación se da en **sistemas informáticos distribuidos**. Un sistema distribuido está formado por un conjunto de ordenadores que pueden estar situados en lugares geográficos diferentes unidos entre ellos a través de una red de comunicaciones.

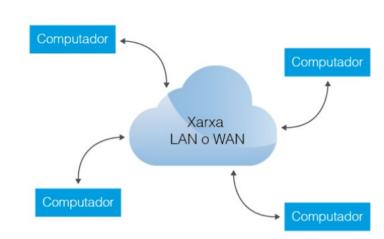


FIGURA 1.6. Execució de programació distribuïda

La **programación distribuida** es un tipo de programación concurrente en la que los procesos son ejecutados en una red de procesadores autónomos o en un sistema distribuido. Es un sistema de computadores independientes que desde el punto de vista del usuario del sistema se ve como una sola computadora.

En los sistemas distribuidos, a diferencia de los sistemas paralelos, no existe memoria compartida, por tanto si necesitan la utilización de variables compartidas se crearán réplicas de estas variables a los diferentes dispositivos de la red y habrá que controlar la coherencia de las datos.

Los principales ventajas son que se trata de sistemas altamente escalables y por tanto reconfigurables fácilmente y de alta disponibilidad. Como desventajas más importantes, encontraremos que son sistemas heterogéneos, complejos de sincronizar. Las comunicaciones se hacen a través de mensajes que utilizan la red de comunicación compartida y eso puede provocar la saturación.

1.1.3 Ventajas y desventajas del multiproceso.

VENTAJAS

Incrementar la potencia de cálculo y el rendimiento es uno de los principales ventajas.

A veces las técnicas de sincronismo o comunicación son más <mark>costosas</mark> en tiempo que la ejecución de los procesos.

Un sistema multiprocesador es **flexible**, ya que, si aumentan los procesos que se están ejecutando es capaz de distribuir la carga de trabajo de los procesadores, y puede también reasignar dinámicamente los recursos de memoria y los dispositivos por ser más eficientes.

Es de **fácil crecimiento**. Si el sistema lo permite, se pueden añadir <mark>nuevos procesadores</mark> de forma sencilla y así aumentan su potencia.

En el último caso hablaremos de sistemas con una **alta tolerancia a fallos**. Una fallo de un procesador no hace que el sistema se paré.

Los sistemas multiproceso nos permiten diferenciar procesos por su **especialización** y, por tanto, reservar procesadores para operaciones complejas, aprovechar otros para procesamientos paralelos y para avanzar la ejecución.

INCONVENIENTES

Los inconvenientes del multiprocesamiento vienen provocados sobre todo por el **control** que se debe realizar cuando hay varios procesos en ejecución y deben compartir información o comunicarse. Eso incrementa la **complejidad** de la programación y penaliza el tiempo de ejecución.

Si el multiprocesamiento es en un entorno multiprocesador paralelo o distribuido, el tráfico de los buses de comunicación se incrementa paralelamente al número de procesadores o computadores que incorporamos al sistema, y eso puede llegar a ser un crítico cuello de botella.

1.2 Procesos y servicios.

Ej: antivirus.

Este proceso que controla las infecciones de todos los ficheros que entran al nuestro ordenador es un **servicio**.

Un **servicio** es un tipo de proceso que <u>no tiene interfaz con el usuario</u>. Pueden ser, dependiendo de su configuración, inicializados por el sistema de forma <mark>automática</mark>, en el que van realizando sus funciones sin que el usuario se enteré o bien se pueden mantener a la <mark>espera</mark> de que alguien les haga una petición para realizar una tarea en concreto.

Dependiendo de como se están ejecutando, los procesos se clasificarán como procesos en primero plan (foreground, en inglés) y procesos en segundo plan (background).

Los procesos en **primero plano** mantienen una comunicación con el usuario, ya sea informando de las acciones realizadas o esperando sus peticiones mediante <u>alguna</u> interfaz de usuario. En cambio, los que se ejecutan en **segundo plano** no se muestran explícitamente al usuario, bien porque no es necesaria su intervención o bien porque los datos requeridos no se incorporan a través de una interfaz de usuario.

Los servicios son procesos ejecutados en segundo plano.

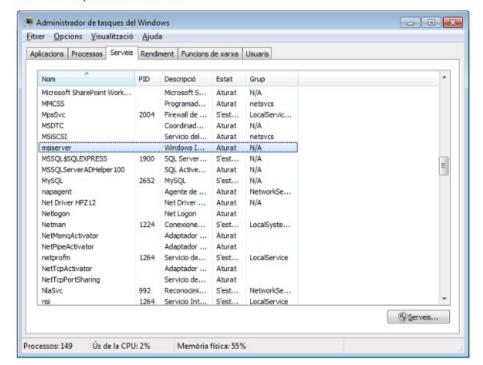


FIGURA 1.7. Serveis Windows

Servicio es una nomenclatura utilizada en Windows. En sistemas Linux se llaman también procesos deamon.

El nombre deamon proviene de las siglas inglesas DAEMON (Disk And Execution Monitor). A menudo a la literatura técnica se ha extendido este concepto usando la palabra "demonio", por el que podéis encontrar esta palabra haciendo referencia en los programas que se ejecutan en segundo plano.

En Linux el nombre de los daemons siempre acaba con la letra d, como por ejemplo httpd, el daemon del http.

Como los servicios no disponen de interfaz de usuario directa, almacenan la información generada o los posibles errores que vayan produciendo, en ficheros de registro habitualmente conocidos como logs.

Algunos servicios pueden estar a la espera de ser llamados por realizar sus funciones. Por ejemplo, <mark>un servidor web tiene un servicio activo</mark>.

Los servicios pueden estar en ejecución local, en nuestro ordenador, como el Firewall, el antivirus, la conexión Wi-Fi, o los procesos que controlan nuestro ordenador, o bien pueden ejecutarse en algún ordenador de un sistema informático distribuido o en Internet, etc. Las llamadas a los servicios distribuidos se realizan sobre protocolos de comunicación. Por ejemplo, los servicios de HTTP, DNS (Domain Name System), FTP (File Transfer Protocol) son servicios que nos ofrecen servidores que están en Internet.

1.2.1 Hilos y procesos.

Ejemplo: cocinero=procesador; receta=programa; paella=recurso; ingredientes=datos; parte de un plato= tarea / subproceso / hilo.

- El cocinero que trabaja simultáneamente preparando un plato para diferentes comensales.
- El procesador de un sistema informático (cocinero) está ejecutando diferentes instancias del mismo programa (la receta).
- El cocinero va realizando las diferentes partes del plato. Si la receta es morcilla con patatas, dividirá su tarea al preparar la morcilla por un lado y las patatas por la otra. Ha dividido el proceso en dos subprocesos. Cada uno de estos subprocesos se llaman hilos.

El sistema operativo puede mantener en ejecución varios procesos a la vez haciendo servir concurrencia o paralelismo.

Además, dentro de cada proceso pueden ejecutarse varios hilos, de manera que bloques de instrucciones que presentan cierta independencia puedan ejecutarse a la vez.

Los hilos comparten los recursos del proceso (datos, código, memoria, etc). En consecuencia, los hilos, a diferencia de los procesos, comparten memoria y si un hilo modifica una variable del proceso, la resto de hilos podrán ver la modificación cuando accedan a la variable.

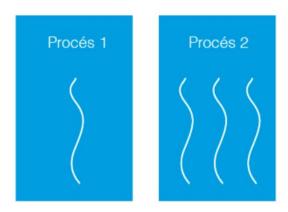
Los procesos son llamados entidades pesadas porque están en espacios de direccionamento de memoria independientes, de creación y de comunicación entre procesos, cosa que consume muchos recursos de procesador. En cambio, ni la creación de hilos ni la comunicación consumen mucho tiempo de procesador. Por este motivo los hilos se llaman entidades ligeras.

Un proceso estará en ejecución mientras algún de sus hilos estuve activo. Aun así, también es cierto que si finalizamos un proceso de forma forzada, sus hilos también acabarán la ejecución.

Podemos hablar de dos niveles de hilos: los **hilos de nivel de usuario**, que son los que creamos cuando programamos con un lenguaje de programación como Java; y los **hilos de segundo nivel** que son los que crea el <mark>sistema operativo</mark> por dar apoyo a los primeros.

En referencia al procesamiento, cada hilo se procesa de forma independiente a pesar de que pertenezca o no a un mismo proceso.

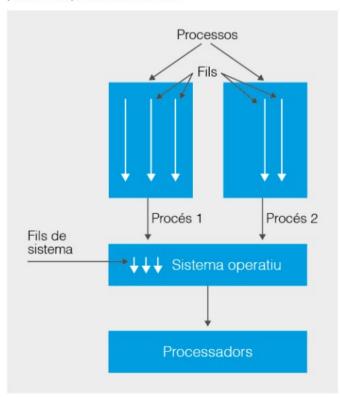
 $F_{1GURA\ 1.8}$. Procés amb un únic fil en execució i procés amb diversos fils en execució



Para hilos de un mismo proceso el sistema operativo debe mantener los mismos datos en memoria.

En caso de que sea necesario que un mismo procesador alterne la ejecución de varios procesos, habrá que restaurar la memoria específica del proceso en cada cambio. Esto se llama cambio de contexto. Si la alternancia de procesamiento se hace entre hilos de un mismo proceso, no hará falta restaurar la memoria y por tanto el proceso será muy más eficiente.

 F_{IGURA} 1.9. Dos processos amb diferents fils en execució. Cada fil s'executa de forma independent. Els fils del mateix procés comparteixen memòria.



1.3 Gestión de procesos y desarrollo de aplicaciones con finalidad de computación paralela.

El tiempo desde que un proceso inicia la ejecución hasta que la finaliza se llama **ciclo de vida del proceso**. Para que el sistema pueda gestionar las necesidades de los procesos durante todo su ciclo de vida, los identificará etiquetándolos con un estado que indiqué las necesidades de procesamiento.

1.3.1 Estados de un proceso.

Todos los sistemas operativos disponen de un planificador de procesos encargado de repartir el uso del procesador de la forma más eficiente posible y asegurando que todos los procesos se ejecuten en algún momento. Para realizar la planificación, el sistema operativo se basará en el estado de los procesos por saber cuáles necesitarán el uso del procesador. Los procesos en disposición de ser ejecutados se organizarán en una cola esperando su turno.

Nou Procés En execució Acabat

Preparat Bloquejat

FIGURA 1.10. Estats d'un procés

El primer estado a que nos encontramos es **nuevo**, es decir, cuando un proceso es creado. Una vez creado, pasa en el estado de **preparado**. En este momento el proceso está preparado para hacer uso del procesador, está compitiendo por el recurso del procesador. El planificador de procesos del sistema operativo es el que decide cuando entra el proceso a ejecutarse. Cuando el proceso se está ejecutando, su estado se llama **en ejecución**. Otra vez, es el planificador el encargado de decidir cuando abandona el procesador.

El planificador de procesos sigue una política que indica cuando un proceso debe cambiar de estado, cuando debe dejar libre o entrar a hacer uso del procesador.

Posible politica del planificador de procesos: asignar diferentes turnos de ejecución. Es decir, asignar un tiempo de ejecución fijo a cada proceso y una vez acabado este tiempo cambiar el proceso del estado de ejecución al estado de preparado. Esperando ser asignado de nuevo al procesador.

Cuando un proceso abandone el procesador, porque el planificador de procesos así la habrá decidido, cambiará al estado de **preparado** y se quedará esperando a que el planificador le asigné el turno para conseguir de nuevo el procesador y volver en el estado de **ejecución**.

Desde el estado de ejecución, un proceso puede pasar en el estado de **bloqueado o en espera**. En este estado, el proceso estará a la espera de un acontecimiento, como puede ser una operación de entrada/salida, o la espera de la finalización de otro proceso, etc. Cuando el acontecimiento esperado suceda, el proceso volverá en el estado de **preparado**, guardando el turno con la resto de procesos preparados.

El último estado es **finalizado/acabado**. Es un estado al que se llega una vez el proceso ha finalizado/terminado toda su ejecución y estará a punto para que el sistema liberé cuando pueda los recursos asociados.

Cada vez que un proceso cambia al estado de ejecución, se llama cambio de contexto, porque el sistema operativo debe almacenar los resultados parciales conseguidos durante la ejecución del proceso saliente y es necesario que cargue los resultados parciales de la última ejecución del proceso entrante en los registros del procesador, asegurando la accesibilidad a las variables y al código que toque seguir ejecutando.

1.3.2 Planificación de procesos.

La planificación de procesos es un conjunto de protocolos o políticas que deciden en qué orden se ejecutarán los procesos al procesador. Estas políticas siguen algunos criterios de prioridad según la importancia del proceso, el tiempo de utilización del procesador, el tiempo de respuesta del proceso, etc.

La función de planificación (scheduler en inglés) del núcleo del sistema operativo, es la encargada de decidir qué proceso entra al procesador, puede dividirse en tres niveles:

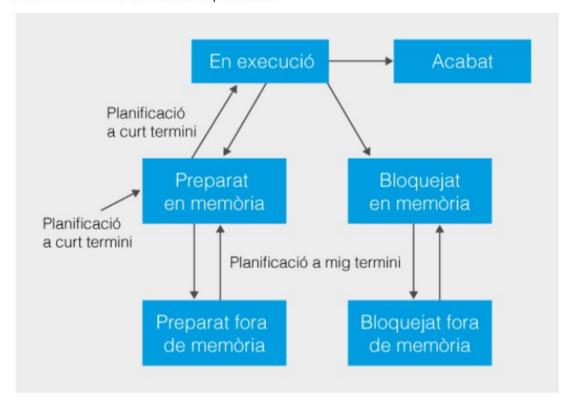


FIGURA 1.11. Planificació de processos

- 1. Planificación a largo plazo: en el momento que se crea un proceso se deciden algunos criterios de planificación, como la unidad de tiempo máximo que un proceso podrá permanecer en ejecución (que se nombra quantum) o la prioridad inicial que se le asignará a cada proceso de forma dinámica por la utilización del procesador.
 - quantum
 - prioridad inicial

- 2. **Planificación a corto plazo**: cada vez que un proceso abandona el procesador hay que tomar la decisión de cuál será el nuevo proceso que entrará a hacer uso. En este caso las políticas intentan minimizar el tiempo necesario para conseguir un cambio de contexto. Los procesos recientemente ejecutados suelen tener prioridad pero hay que asegurar que nunca se excluya permanentemente ningún proceso de la ejecución.
 - Minimizar cambio de contexto. Procesos recientemente usados.
- 3. **Planificación a medio plazo**: existen otros partes del sistema operativo que también son importantes a la planificación de procesos. En el caso del **SWAP de memoria**, si se quita un proceso de la memoria por problemas de espacio hace que no pueda ser planificable de forma inmediata. El planificador a medio plazo será el encargado de decidir cuando es preciso llevar a la memoria principal las datos de los procesos almacenados fuera y cuáles habrá que trasladar de la memoria principal al espacio de intercambio.
 - Memoria principal (RAM).
 - Memoria secundaria (disco).

Los **sistemas multiprocesadores** presentan además dos componentes de planificación específicos.

El componente de **planificación temporal** en el que se encuentra definida la política de planificación que actúa sobre cada procesador de forma individual, como si fuera un sistema monoprocessador. El planificador temporal decide cuando de tiempo ha que dedicar a procesar cada proceso, cuando es preciso hacer cambiar, por qué motivo, etc.

El componente de **planificación espacial**, en el que se define como se reparten los **procesos** entre los **procesadores**. Es decir, organiza qué procesador ejecuta qué proceso.

Una política de **afinidad al procesador** puede provocar una sobrecarga en algunos procesadores y hacer que la ejecución no sea demasiado eficiente. Por contra, una política de **reparto de carga** evita esta supuesta infrautilización de algunos procesadores, pero aumenta las sobrecargas en la memoria compartida.

1.3.3 Programación paralela transparente.

Cuando buscamos resultados rápidamente o mucha potencia de cálculo podemos pensar al aumentar el número de procesadores de nuestra computadora y ejecutar una aplicación de forma paralela a los diferentes procesadores. Pero la ejecución en paralelo no es siempre posible. En primer lugar porque hay aplicaciones que no se pueden paralelizar, sino que su ejecución debe ser secuencial. Y en segundo lugar, por la dificultad para desarrollar entornos de programación en sistemas paralelos, ya que se requiere un esfuerzo importante de los programadores.

Java proporciona apoyo a la programación concurrente con librerías de bajo nivel a través de la clase **java.lang.Thread** y de la interfaz **java.lang.Runnable**. Hay problemas que pueden programarse de forma paralela siguiendo patrones semejantes. El uso de Thread y Runnable comporta un esfuerzo adicional del programador, obligándolo a añadir pruebas extras para verificar el comportamiento correcto del código, evitando lecturas y escrituras erróneas, **sincronizando** las ejecuciones de los procesos y evitando los problemas derivados de los **bloqueos**.

Una aproximación relativamente sencilla a algunos de estos problemas que pueden resolverse de forma paralela con implantaciones típicas que presentan un cierto nivel de patronazgo son los marcos predefinidos de programación paralela del lenguaje a Java: **Ejecutor** y **fork-join**. Son librerías que encapsulan buena parte de la funcionalidad y con ella de la complejidad adicional que la programación de más bajo nivel (Threads) presenta.

1.4 Sincronización y comunicación entre procesos.

Las técnicas que nos ayudan a controlar la orden de ejecución de los diferentes procesos se denominan técnicas de comunicación y sincronización.

1.4.1 Competencia de recursos y sincronización.

Los procesos concurrentes se pueden clasificar en independientes o cooperantes según su grado de colaboración. Un proceso independiente no necesita ayuda ni cooperación de otros procesos. En cambio, los procesos cooperantes están diseñados por trabajar conjuntamente con otros procesos y, por tanto, se han de poder comunicar e interactuar entre ellos.

En la programación concurrente el **proceso de sincronización** permite que los procesos que se ejecutan de forma simultánea se coordinen, parando la ejecución de aquellos que vayan más avanzados hasta que se cumplan las condiciones óptimas para estar seguros que los resultados finales serán correctos.

Para sincronizar procesos podemos hacer servir diferentes métodos:

- Sincronismo condicional: o condición de sincronización. Un proceso o hilo se encuentra en estado de ejecución y pasa en estado de bloqueo esperando que una cierta condición se cumpla para continuar su ejecución. Otro proceso hace que esta condición se cumpla y así el primer proceso pasa de nuevo al estado de ejecución.
- Exclusión mutua: se produce cuando dos o más procesos o hilos quieren acceder a un recurso compartido. Se deben establecer protocolos de ejecución para que no accedan de forma concurrente al recurso.
- Comunicación por mensajes: en la que los procesos se intercambian mensajes para comunicarse y sincronizarse. Es la comunicación típica en sistemas distribuidos y es utilizada también en sistemas no distribuidos.

1.4.2 Sincronización y comunicación.

Secciones críticas

Las secciones críticas son uno de los problemas que con más frecuencia se dan en programación concurrente. Tenemos varios procesos que se ejecutan de forma concurrente y cada uno de ellos tiene una parte de código que se debe ejecutar de forma exclusiva ya que accede a recursos compartidos como ficheros, variables comunes, registros de bases de datos, etc.

La solución pasará por obligar a acceder a los recursos a través de la ejecución de un código que llamaremos sección crítica y que nos permitirá proteger aquellos recursos con mecanismos que impidan la ejecución simultánea de dos o más procesos dentro los límites de la sección crítica.

El algoritmo de sincronización que evita el acceso a una región crítica por más de un hilo o proceso y que garantiza que únicamente un proceso estará haciendo uso de este recurso y el resto de hilos/procesos que quieren utilizarlo estarán a la espera de que sea liberado, se llama algoritmo de exclusión mutua.

Exclusión mutua (MUTEX, mutual exclusión en inglés) es el tipo de sincronización que impide que dos procesos ejecuten simultáneamente una misma sección crítica.

Para validar cualquier mecanismo de sincronización de una sección crítica se han de cumplir los siguientes criterios:

- Exclusión mutua: no puede haber más de un proceso simultáneamente en la sección crítica.
- **No inanición**: un proceso no puede esperar un tiempo indefinido para entrar a ejecutar la sección crítica.
- **No interbloqueo**: ningún proceso de fuera de la sección crítica puede impedir que otro proceso entre en la sección crítica.
- **Independencia del hardware**: inicialmente no se deben hacer suposiciones con respecto al número de procesadores o la velocidad de los procesos.

Productor-consumidor

El problema productor-consumidor es un ejemplo clásico donde hay que dar un tratamiento independiente a un conjunto de datos que se van generando de forma más o menos aleatoria o cuando menos de una forma en que no es posible predecir en qué momento se generará un dato. Para evitar un uso excesivo de los recursos del ordenador esperando la llegada de datos, los sistema prevé dos tipos de procesos: los productores, encargados de obtener los datos a tratar y los consumidores, especializados al hacer el tratamiento de los datos obtenidos por los productores.

En esta situación el productor genera una serie de datos que el consumidor recoge. Imaginamos que es el valor de una variable que el productor modifica y el consumidor toma para utilizarla. El problema viene cuando el productor produce datos a un ritmo diferente del que el consumidor utiliza/recoge.

El productor crea una dato y cambia la variable a su valor. Si el consumidor va más lento, el productor tiene tiempo a generar un nuevo dato y vuelve a cambiar la variable. Por tanto, el proceso del consumidor ha perdido el valor del primer dato.

En caso de que sea el consumidor el que va más rápido, puede pasar que tome dos veces un mismo dato, ya que el productor no ha tenido tiempo de sustituirlo, o que no encuentre nada para consumir. La situación puede complicarse aún más si disponemos de diversos procesos productores y consumidores.

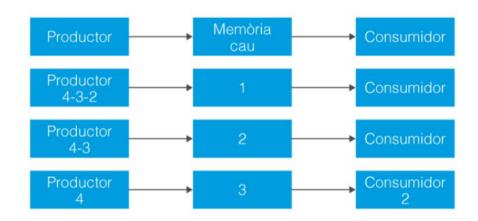


FIGURA 1.13. Productor-consumidor

FIGURA 1.14. Buffer



Un buffer es un espacio de memoria para almacenar datos. Se pueden implementar en forma de colas.

Por tanto, debe existir un mecanismo que paré el acceso al dato de los productores y de los consumidores. En caso necesario, una sección crítica. Desgraciadamente no hay suficiente con restringir el acceso a las datos, porque podría darse el caso de que un proceso consumidor esperara la llegada de un dato e impidiera el acceso de los procesos productores de forma que el dato no llegase nunca. Una situación como la descrita se conoce con el nombre de problemas de interbloqueo (deadlock en inglés).

Llamamos **interbloqueo** a la situación extrema a que nos encontramos cuando <mark>dos o más procesos están esperando</mark> la ejecución del otro para poder continuar de manera que nunca conseguirán desbloquearse.

También llamamos **inanición** a la situación que se produce cuando un proceso no puede continuar su ejecución por falta de recursos. Por ejemplo, si hiciéramos crecer el buffer ilimitadamente.

Por solucionar el problema hay que sincronizar el acceso al buffer. Se debe acceder en exclusión mutua para que los productores no alimenten el buffer si este ya está lleno y los consumidores no puedan acceder si está vacío. Pero además habrá que independizar las secciones críticas de acceso de los productores de las secciones críticas de acceso de los consumidores evitando así que se pueda producir el interbloqueo.

Eso obligará a crear un mecanismo de **comunicación** entre secciones críticas de manera que cada vez que un productor dejé un dato disponible, avisé a los consumidores que puedan quedar esperando y que por lo menos uno de ellos pueda iniciar el procesamiento de la dato.

Lectores-escritores

Otro tipo de problema que aparece en la programación concurrente, es el producido cuando tenemos un recurso compartido entre varios procesos concurrentes como pueden ser un fichero, una base de datos, etc. que va actualizándose periódicamente. En este caso, los procesos lectores no consumen la dato sino que solo lo utilizan y por tanto, se permite su consulta de forma simultánea, a pesar de que no su modificación.

Así, los procesos que accedan al recurso compartido para leer su contenido se llamarán **lectores**. En cambio, los que accedan para modificarlo recibirán el nombre de **escritores**.

Si la tarea de lectores y escritores no se realiza de forma coordinada podría pasar que un lector leyese varias veces el mismo dato o que el escritor modificara el contenido antes de que hubieran leído todos los lectores, o que el dato actualizado por un escritor malbaratase la actualización de otro, etc. Además, la falta de coordinación obliga a los lectores a comprobar periódicamente si los escritores han hecho modificaciones. Esto hará aumentar el uso del procesador y por tanto podría menguar la eficiencia.

Este problema de sincronización de procesos se llama problema de lectoresescritores. Para evitarlo hay que asegurar que los procesos escritores acceden de forma exclusiva al recurso compartido y que a cada modificación se avisa a los procesos lectores interesados en el cambio.

Así, los procesos lectores pueden quedar en espera hasta que son avisados de que hay nuevos datos y pueden empezar a leer; de esta manera se evita que los lectores estén constantemente accediendo al recurso sin que el escritor haya puesto ningún dato nuevo, optimizando, de esta manera, los recursos.

1.4.3 Soluciones a problemas de sincronización y comunicación.

A lo largo de la historia se han propuesto soluciones específicas para los problemas anteriores que vale la pena tener en cuenta, a pesar de que resulta difícil generalizar una solución ya que dependen de la complejidad, la cantidad de secciones críticas, del número de procesos que requieran exclusión mutua y de la interdependencia existente entre procesos. Aquí veremos la sincronización mediante semáforos, de monitores y de paso de mensajes.

Semáforos

Los semáforos son una técnica de sincronización de memoria compartida que impide la entrada del proceso a la sección crítica bloqueándolo. El concepto fue introducido por el informático holandés **Dijkstra** para resolver el problema de la **exclusión mutua** y permitir resolver gran parte de los problemas de sincronización entre procesos.

Los semáforos, no solo controlan el acceso a la sección crítica sino que además disponen de información complementaria por poder decidir si es preciso o no bloquear el acceso de aquellos procesos que lo soliciten. Así por ejemplo, serviría por solucionar problemas sencillos (con poca interdependencia) del tipo escritores-lectores o productores-consumidores.

La solución por ejemplo en el caso de los escritores-lectores pasaría por hacer que los **lectores** antes de consultar la sección crítica pidieran permiso de acceso al semáforo, el cual en función de sí se encuentra bloqueado (rojo) o liberado (verde) detendrá la ejecución del proceso solicitante o bien le dejará continuar.

Los **escritores** por otra parte, antes de entrar a la sección critica, manipularán el semáforo poniéndolo en rojo y no lo volverán a poner en verde hasta que hayan acabado de escribir y abandonen la sección crítica.

De forma genérica distinguiremos 3 tipos de operaciones en un semáforo:

El semáforo admite 3 operaciones:

- Inicializa (initial): se trata de la operación que permite poner en marcha el semáforo. La operación puede recibir un valor por parámetro que indicará si este empezará boqueado (rojo) o liberado (verde).
- Libera (sendSignal): cambia el valor interno del semáforo poniéndolo en verde (libera). Si existen procesos en espera, los activa para que finalicen su ejecución.
- Bloquea (sendWait): sirve para indicar que el proceso actual quiere ejecutar a sección crítica. En caso de que el semáforo se encuentre bloqueado, se para la ejecución del proceso. También permite indicar que hay que poner el semáforo en rojo.

En caso de que se necesité exclusión mutua, el semáforo dispondrá también de un sistema de espera (mediante colas de procesos) que garantice el acceso a la sección crítica de un único proceso a la vez.

Además de resolver problemas de tipo productor-consumidor o lector-escritor, podemos hacer servir semáforos por gestionar problemas de sincronización donde un proceso tenga que activar la ejecución de otro o de exclusión mutua asegurando que solo un proceso conseguirá acceder a la sección crítica porque el semáforo quedará bloqueado hasta la salida.

Otro ejemplo que puede ilustrar el uso de semáforos, sería el de una oficina bancaria que gestiona nuestro cuenta corriente al que se puede acceder desde diferentes oficinas para ingresar dinero o sacar dinero. Estas dos operaciones modifican nuestro saldo. Serían dos funciones como las siguientes:

```
public void ingresar(float dinero) {
    float aux;
    aux=llegirSaldo();
    aux=aux+dinero;
    saldo=aux;
    guardarSaldo(saldo);
    }

public void sacar(float dinero) {
    float aux;
    aux=llegirSaldo();
    aux=aux - dinero;
    saldo=aux;
    guardarSaldo(saldo);
    }
```

Para evitar el problema podemos utilizar un semáforo. Le iniciaremos a 1, indicando el número de procesos que podrán entrar a la sección crítica. Y tanto en el proceso de sacar dinero como en el de ingresar añadiremos un sendWait() al inicio de las secciones críticas y un sendSignal() al final.

```
public void ingresar(float dinero) {
     sendWait();
     float aux;
     aux=llegirSaldo();
     aux=aux+dinero;
     saldo=aux;
     quardarSaldo(saldo);
     sendSignal();
     public void sacar(float dinero) {
          sendWait();
          float aux;
          aux=llegirSaldo();
          aux=aux - dinero;
          saldo=aux;
          quardarSaldo(saldo);
          sendSignal();
          }
```

De esta forma cuando un proceso entra a la sección crítica de un método, coge el semáforo. Si es 1, podrá hacer el sendWait, por tanto el semáforo se pondrá a 0, cerrado. Y ningún otro proceso no podrá entrar a ninguno de los dos métodos. Si un proceso intenta entrar, encontrará el semáforo a 0 y quedará bloqueado hasta que el proceso que tiene el semáforo envíe un sendSignal, ponga el semáforo a 1 y libere el semáforo.

Utilizar semáforos es una forma eficiente de sincronizar procesos concurrentes. Resuelve de forma simple la exclusión mutua. Pero desde el punto de vista de la programación, los algoritmos son complicados de diseñar y de entender, ya que las operaciones de sincronización pueden estar dispersas por el código. Por tanto se pueden cometer errores con facilidad.

Monitores

Otra forma de resolver la sincronización de procesos es el uso de monitores. Los monitores son un conjunto de procedimientos encapsulados que nos proporcionan el acceso a recursos compartidos a través de varios procesos en exclusión mutua.

Las operaciones del monitor están encapsuladas dentro de un módulo para protegerlas del programador. Únicamente un proceso puede estar en ejecución dentro de este módulo.

Un monitor se puede ver como una habitación, cerrada con una puerta, que tiene adentro los recursos. Los procesos que quieran utilizar estos recursos tienen que entrar en la habitación, pero con las condiciones que marca el monitor y únicamente un proceso a la vez. El resto que quiera hacer uso de los recursos tendrá que esperar a que salga el que es dentro.

Por su encapsulación, la única acción que tiene que tomar el programador del proceso que quiera acceder al recurso protegido es informar al monitor. La exclusión mutua está implícita. Los semáforos, en cambio, se tienen que implementar con una secuencia correcta de señal y esperar para no bloquear el sistema.

Un monitor es un algoritmo que hace una abstracción de datos que nos permite representar de forma abstracta un recurso compartido mediante un conjunto de variables que definen su estado. El acceso a estas variables únicamente es posible desde unos métodos del monitor.

El monitor tiene que poder incorporar un mecanismo de sincronización. Por lo tanto, se tienen que implementar. Se puede hacer uso de señales. Estas señales se utilizan para impedir los bloqueos. Si el proceso que está en el monitor tiene que esperar una señal, se pone en estado de espera o bloqueado fuera del monitor, permitiendo que otro proceso haga uso del monitor. Los procesos que están fuera del monitor, están a la espera de una condición o señal para volver a entrar.

Estas variables que se utilizan por las señales y son utilizadas por el monitor para la sincronización se denominan **variables de condición**. Estas pueden ser manipuladas con operaciones de **sendSignal** y **sendWait** (como los semáforos).

- **sendWait**: un proceso que está esperando a un acontecimiento indicado por una variable de condición abandona de forma temporal el monitor y se pone a la cola que corresponde a su variable de condición.
- **sendSignal**: desbloquea un proceso de la cola de procesos bloqueados con la variable de condición indicada y se pone en estado preparado para entrar al monitor. El proceso que entra no tiene que ser el que más tiempo lleva esperando, pero se tiene que garantizar que el tiempo de espera de un proceso sea limitado. Si no existe ningún proceso en la cola, la operación sendSignal no tiene efecto, y el primer proceso que pida el uso del monitor entrará.

Un monitor consta de 4 elementos:

- Variables o métodos permanentes o privados: son las variables y métodos internos al monitor que solo son accesibles desde dentro del monitor. No se modifican entre dos llamamientos consecutivos al monitor.
- Código de inicialización: inicializa las variables permanentes, se ejecuta cuando el monitor es creado.
- Métodos externos o exportados: son métodos que son accesibles desde fuera del monitor por los procesos que quieren entrar a hacer uso.
- Cola de procesos: es la cola de procesos bloqueados a la espera de la señal que los libere para volver a entrar al monitor.

En el campo de la programación <mark>un monitor es un objeto en el cual todos sus métodos están implementados bajo exclusión mutua</mark>. En el lenguaje Java son objetos de una clase en los cuales todos sus métodos públicos son **synchronized**.

Un <mark>semáforo</mark> es un <mark>objeto</mark> que permite sincronizar el acceso a un recurso compartido y un monitor es una interfaz de acceso al recurso compartido. Es el encapsulamiento de un objeto, aquello que hace un objeto más seguro, robusto y escalable.

wait, notify y notifyAll, son operaciones que permiten sincronizar el monitor.

Sincronizar en Java

En Java la ejecución de objetos no está protegida. Si queremos aplicar exclusión mutua en Java tenemos que utilizar la palabra reservada **synchronized** en la declaración de atributos, de métodos o en un bloque de código dentro de un método.

Todos los métodos con el modificador **synchronized** se ejecutarán en exclusión mutua. El modificador asegura que si se está ejecutando un método sincronizado ninguno otro método sincronizado se pueda ejecutar. Pero los métodos no sincronizados pueden estar ejecutándose y con más de un proceso a la vez. Además, <mark>únicamente el método sincronizado puede estar ejecutado por un proceso</mark>, el resto de procesos que quieren ejecutar el método se tendrán que esperar a que acabe el proceso que lo está ejecutando.

Método:

```
public synchronized void metodeSincronitzat {
    //parte de código sincronizado,
    //se ejecuta en exclusión mutua
}
```

Bloque de código:

```
public void metodeNoSincronitzat {
    //part de codi sense sincronitzar

    synchronized(this) {
        //part de codi sincronitzat
      }

    //part de codi sense sincronitzar
}
```

this es el objeto que ha llamado al método, pero también podemos utilizar otro objeto **synchroniced(objeto)**, si lo que queremos es realizar más de una operación atómica sobre un objeto.

Java, por lo tanto, nos proporciona con **synchronized** los recursos que nos daría la implementación de un **semáforo** o de un **monitor**. Sus librerías nos proporcionan un acceso en exclusión mutua y controlan los errores de bloqueo o interbloqueo que se puedan ocasionar entre los hilos en ejecución.

Atomicidad de una operación y clases atómicas de Java

El único árbitro que tenemos en la gestión de procesos es el planificador. Se encarga de decidir qué proceso hace uso del procesador. Después las instrucciones u operaciones que forman el proceso se van ejecutando en ell procesador siguiendo un orden concreto. Una operación o un grupo de operaciones se tienen que poder ejecutar como si fueran una única instrucción. Además, no se pueden ejecutar de forma concurrente con cualquier otra operación en la cual haya involucrada un dato o recurso que utiliza la primera operación.

El atomicidad de una operación es poder garantizar que no se pueden ejecutar dos operaciones de forma concurrente si hacen uso de un recurso compartido hasta que una de las dos deja libre este recurso. Una operación atómica únicamente tiene que observar dos estados: el inicial y el resultado. Una operación atómica, o se ejecuta completamente o no lo hace en absoluto.

La **atomicidad real** son las instrucciones que ejecutan en código máquina. En cambio, la **atomicidad modelo** es un grupo de instrucciones, en código máquina, que se ejecuta de forma atómica.

Clases de operaciones atómicas

La instrucción x++; o x=x+1; tiene la siguiente secuencia de instrucciones atómicas reales:

- 1. Leer valor x
- 2. Añadir a x1
- 3. Guardar valor x

La atomicidad de modelo entiende la instrucción completa, x = x + 1 como atómica.

Dos procesos ejecutan en paralelo el siguiente ejemplo:

```
package operacionsatomiques;
public class OperacionsAtomiques {
    public static void main(String[] args) {
        int x=0;
        x=x+1; //esta operación en Java no es atómica
        System.out.println(x);
     }
}
```

Clases atómicas en Java

Las clases atómicas de Java son una primera solución a los problemas de procesos concurrentes. Permiten ejecutar algunas operaciones como si fueran atómicas reales.

Una operación atómica tiene únicamente dos estados: el inicial y el resultado, es decir, se completa sin interrupciones desde el inicio hasta el final.

En Java, el <u>acceso</u> a las variables de tipos primitivos (excepto double y long) es atómico. Como también es atómico el acceso a todas las variables de tipo primitivo en las cuales aplicamos el modificador volatile.

NOTA: **volatile** es un modificador, utilizado en la programación concurrente, que se puede aplicar a algunos tipos primitivos de variables. Indica que el valor de la variable quedará guardado en la memoria y no en un registro del procesador. Así, es accesible por otro proceso o hilo para modificarla. Por ejemplo: **volatile int c**;

Java asegura la atomicidad del acceso a las variables volátiles o primitivas, pero no a sus operaciones. Esto quiere decir que la operación x++; en la cual x es un int, no es una operación atómica y por tanto no es un hilo seguro.

Java incorpora, desde la versión 1.5, en el paquete **java.util.concurrent.atomic**, las clases que nos permiten convertir en atómicas (hilos seguros) algunas operaciones, como por ejemplo aumentar, reducir, actualizar y añadir un valor. Todas las clases tienen métodos **get** y **set** que también son atómicos.

Las clases que incorpora son: AtomicBoolean, AtomicInteger, AtomicIntegerArray, AtomicLong, AtomicLongArray y actualizadores que son básicamente derivados de una variable tipo volatile que son AtomicIntegerFieldUpdater, AtomicLongFieldUpdater y AtomicReferenceFieldUpdater.

https://docs.oracle.com/en/java/javase/11/docs/api/java.base/java/util/concurrent/atomic/ AtomicInteger.html

https://docs.oracle.com/en/java/javase/11/docs/api/java.base/java/util/concurrent/atomic/ AtomicIntegerFieldUpdater.html Por lo tanto, podemos convertir la operación x++ o x=x+1 en una operación atómica .

```
public class Comptador {
    private int x = 0;

    public void augmenta() {
        x++;
        }

    public void disminueix() {
        x -- ;
        }

    public int getValorComptador() {
        return x;
        }
}
```

Para convertir en operaciones atómicas el ejemplo anterior, utilizaremos los métodos de la clase **AtomicInteger** del paquete **java.util.concurrent.atomic.AtomicInteger**.

```
import java.util.concurrent.atomic.AtomicInteger;
public class ContadorAtomic {
    private AtomicInteger x = new AtomicInteger(0);
    public void augmenta() {
        x.incrementAndGet();
     }
    public void disminueix() {
        x.decrementAndGet();
     }
    public int getValorContadorAtomic() {
        return x.get();
     }
    }
}
```

https://docs.oracle.com/javase/6/docs/api/java/util/concurrent/atomic/package-summary.html

https://docs.oracle.com/en/java/javase/11/docs/api/java.base/java/util/concurrent/atomic/ AtomicInteger.html

Colecciones concurrentes

Las colecciones son objetos que contienen múltiples datos de un mismo tipo. Lascolecciones pueden estar involucradas también en la ejecución de procesos concurrentes y ser utilizadas por diferentes procesos de forma que se acaben compartiendo también los datos contenidos a la colección.

En Java para trabajar con colecciones tenemos que utilizar el **Framework Collections** en el cual se encuentran los paquetes **java.util** y **java.util.concurrent**, que contienen las clases e interfaces que nos permiten crear colecciones.

En Java las interfaces **List<E>**, **Set<E>** y **Queue<E>** serian las colecciones más importantes. Representan listas, conjuntos y colas. Map<E> es también una colección de key/valor. Cada una con sus características de ordenación, los métodos de inserción, de extracción i consulta, si permiten elementos repetidos o no, etc.

El problema con estas colecciones es que en la programación concurrente en la cual sean compartidas por diferentes procesos o hilos de forma simultánea, podrían dar resultados inesperados.

Algunos lenguajes de programación solucionaron este problema sincronizando las clases. En Java se utiliza, por ejemplo, Collections.synchronizedList(List<T> list) sobre la interfaz List<E> para poder sincronizar la clase que la implementa, la clase ArrayList. Otras clases que implementan la interfaz List es Vector. Java ya sincroniza esta clase.

En la versión 1.5 apareció **java.util.concurrent** que incorpora clases que nos permiten solucionar problemas de concurrencia de una forma simple.

ArrayList es una colección de datos y si queremos que sea utilizada por diferentes hilos de ejecución lo que tenemos que hacer es sincronizar todas las operaciones de lectura y escritura para preservar la integridad de los datos. Si este ArrayList es muy consultado y poco actualizado, la sincronización penaliza mucho el acceso. Java crea la clase CopyOnWriteArrayList, que es la ejecución de hilo seguro de una ArrayList.

NOTA:

La clase **CopyOnWriteArrayList** cada vez que se modifica el **array** se crea en la memoria un **array** con el contenido sin procesos de sincronización. Esto hace que las consultas no sean tan costosas.

La interfaz **BlockingQueue** implementa una cola FIFO, que bloquea el hilo de ejecución si intenta sacar de la cola un elemento y la cola está vacía o si intenta insertar un elemento y está llena. También contiene métodos que hacen que el bloqueo dure un tiempo determinado antes de dar un error de inserción o lectura y así evitar una ejecución infinita.

NOTA:

La cola FIFO (en inglés, First In Firts Out) es una estructura de datos implementada de forma que los primeros elementos al entrar a la estructura son los primeros al salir.

La clase **SynchronousQueue** es una cola de bloqueo, implementa la interfaz **BlockingQueue**. Lo que hace es que por cada operación de inserción tiene que esperar una de eliminación y por cada inserción tiene que esperar una eliminación.

https://docs.oracle.com/en/java/javase/11/docs/api/java.base/java/util/concurrent/ SynchronousQueue.html

ConcurrentMap es otra clase que define una table *hash* con operaciones atómicas.

Podéis encontrar más información sobre el paquete en la página oficial de Java. http://docs.oracle.com/javase/6/docs/api/java/util/concurrent/package-summary.html

Comunicación con mensajes

Una solución a los problemas de concurrencia de procesos, muy adecuada sobre todo para los <mark>sistemas distribuidos</mark>, son los <mark>mensajes</mark>. Recordamos que un sistema distribuido no comparte memoria, por lo tanto no es posible la comunicación entre procesos con variables compartidas.

Este sistema de sincronización y comunicación está incluido en la mayoría de sistemas operativos y se usa tanto por la comunicación entre diferentes ordenadores, como para comunicar entre procesos de una mismo ordenador. La comunicación a través de mensajes siempre necesita un proceso emisor y otro de receptor para poder intercambiar información. Por lo tanto, las operaciones básicas serán enviar(mensaje) y recibir(mensaje).

Dado que en esta comunicación pueden estar implicados varios procesos, hay que permitir a las operaciones básicas identificar quién es el destinatario e incluso convendría en ocasiones identificar el emisor. Habrá que extender las operaciones básicas incorporando a quién va dirigido el mensaje o cómo el receptor podría indicar de quién espera el mensaje.

Según la forma de referenciar el <mark>destinatario y el emisor</mark>, hablaremos de envío de mensajes en **comunicación directa** o **comunicación indirecta**.

En la **comunicación directa**, el emisor identifica el <mark>receptor</mark> explícitamente cuando envía un mensaje y viceversa, el receptor identifica explícitamente el emisor que le envía el mensaje. Se crea un enlace de comunicación entre el proceso emisor y proceso receptor. Las órdenes de envío y recepción serían:

enviar(A,mensaje) -> Enviar un mensaje al proceso A
recibir(B, mensaje) -> Recibir un mensaje del proceso B

Este sistema de comunicación ofrece una gran seguridad, puesto que identifica los procesos que actúan en la comunicación y no introduce ningún retraso a la hora de identificar los procesos. Por otro lado, esto también es una desventaja, puesto que cualquier cambio en la identificación de procesos implica un cambio en la codificación de las órdenes de comunicación.

La comunicación directa solo es posible de implementar si podemos identificar los procesos. Es decir, hará falta que el sistema operativo y el lenguaje de programación soporten la gestión de procesos. También hace falta que los procesos se ejecuten en un mismo ordenador, puesto que sino es imposible acceder de forma directa.

Cuando los procesos se ejecuten en diferentes ordenadores, será necesario interponer entre ellos un sistema de mensajería que envíe y recoja los mensajes con independencia de que sea el proceso emisor y receptor. Solo hará falta que ambos procesos tengan acceso al mismo sistema de intercambio de mensajes y que este permita identificar de alguna manera el emisor y el receptor. Hay que darse cuenta que se trata identificación interna del sistema de mensajería. En ningún caso son referencias directos a los procesos.

En la **comunicación indirecta** se desconocen las referencias a los procesos emisor y receptor del mensaje. Es necesaria la existencia de un sistema de mensajería capaz de distribuir mensajes identificados con algún valor específico y único, y permitir a los procesos la consulta de los mensajes a partir de este identificador para discernir los que vayan dirigidos a ellos. En cierta forma es como vehicular la comunicación a través de un buzón común (el identificador). El emisor envía el mensaje a un buzón específico y el receptor recoge el mensaje del mismo buzón.

Las órdenes serían de la siguiente forma: enviar(Buzon_A,mensaje) → El proceso emisor deja el mensaje en el buzón A recibir(Buzon_A,mensaje) → El proceso receptor recoge el mensaje del buzón A

Este sistema es más flexible que la comunicación directa puesto que nos permite tener más de un enlace de comunicaciones entre los dos procesos y podemos crear enlaces de tipos uno a muchos, muchos a uno y muchos a muchos. En los enlaces de comunicación uno a muchos como por ejemplo los sistemas cliente/servidor los buzones se denominan puertos.

Estos múltiples enlaces no se podrían hacer con el sistema de comunicación directa. El sistema operativo es el encargado de realizar la asociación de los buzones a los procesos y lo puede hacer de forma dinámica o estática.

Por otro lado, si tenemos en cuenta la inmediatez en la recepción de los mensajes entre procesos hablaremos de: comunicación **síncrona** o **asíncrona**.

En la comunicación síncrona el proceso que envía un mensaje a otro proceso se queda a la espera de recibir respuesta. Por lo tanto, el emisor queda bloqueado hasta que recibe esta respuesta. Y viceversa. En cambio en la comunicación asíncrona el proceso que envía el mensaje continúa su ejecución sin preocuparse de si el mensaje ha sido recibido o no. Por lo tanto, aquí tendrá que existir una memoria intermedia o que se vayan acumulando los mensajes. El problema vendrá cuando la memoria intermedia se encuentre llena. El proceso que envía el mensaje queda bloqueado hasta que encuentra el espacio dentro de la memoria intermedia.

Un símil a estos dos tipos de sincronización podría ser el envío de mensajes a través de correo electrónico o de chat. El primero, que va dejando los mensajes a un buzón sin preocuparse si los receptor lo recibe o no, sería una comunicación asíncrona. En cambio en un chat la comunicación es totalmente síncrona puesto que el emisor y el receptor tienen que coincidir en el tiempo.

Implementación usando Java

La comunicación y sincronización entre procesos de ordenadores diferentes conectados en red (sistemas distribuidos) requieren de un mecanismo de transferencia que asuma la comunicación indirecta, los sockets. Se trata de unas bibliotecas que disponen de todos los mecanismos necesarios para enviar y recibir mensajes a través de la red.

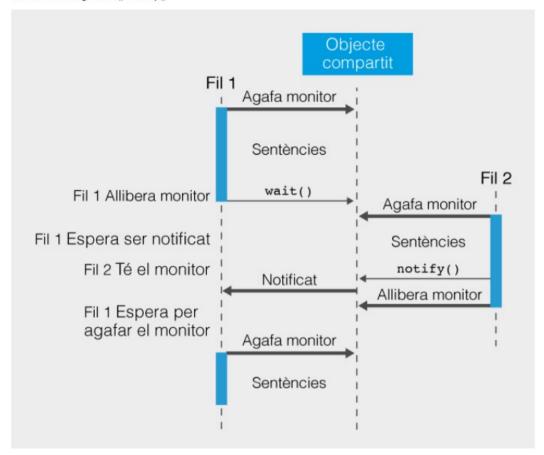
Dentro del mismo ordenador, Java dispone de métodos como wait(), notify() y notifyAll(), que modifican el estado de un hilo parando o activando la ejecución de los procesos referenciados. Estos métodos tienen que ser invocados siempre dentro de un bloque sincronizado (con el modificador synchronize).

- wait(): pone el hilo que se está ejecutando en estado de espera. Este hilo abandona la zona de exclusión mutua y espera, en una cola de espera, a ser vuelto a a activar por un método notify() o notifyAll().
- notify(): un hilo de la cola de espera pasa en el estado de preparado.
- notifyAll(): todos los hilos de la cola de espera pasan en el estado de preparado.

Cuando un proceso entra en la sección crítica, es decir que controla el monitor, ninguno otro hilo puede entrar a la sección crítica del mismo objeto que está controlado por el mismo monitor. Para poder coordinarse y comunicarse se harán uso del métodos anteriores.

Cuando no se dan las condiciones para continuar con la ejecución de un hilo que se encuentra a la sección crítica, este puede abandonar la sección y permitir que otro hilo que se encuentra en espera pueda coger el monitor y entrar a la sección crítica. En la siguiente figura (figura 1.15) se muestra como dos hilos quieren acceder a un recurso común y se comunican para sincronizarse. Imaginamos que el recurso compartido es una tarjeta SIM de un teléfono móvil.

FIGURA 1.15. wait() i notify()



El hilo 1 quiere acceder a la tarjeta para hacer una llamada, coge el monitor del recurso compartido para tener acceso exclusivo a la tarjeta, pero la SIM no está activada todavía. La condición para poder ejecutarse no se cumple. Por lo tanto, ejecuta el método wait() que lo mantiene en espera hasta que la condición se cumpla. Cualquier otro proceso que quiera hacer la llamada y coja el monitor hará el mismo, ejecutará el método wait() y se quedará a la cola de espera.

El hilo 2 es un proceso que se encarga de activar la tarjeta SIM. Cuando coge el monitor tiene acceso con exclusión mutua a la tarjeta. Hace las sentencias para activar la SIM y ejecuta notify() . Esta sentencia notifica al primer hilo, que está a la cola de procesos en espera, que ya se cumplen las condiciones para poder continuar la ejecución de los procesos de llamadas y libera el monitor. La diferencia entre notify() y notifyAll() es que la notificación se hace a un hilo en espera o a todos. Por último, el hilo 1 coge el monitor y ejecuta la suyas sentencias de llamada.

En Java, haciendo uso de **synchronized** se crean **semáforos**. Si añadimos los métodos **wait()**, **notify()** o **notifyAll()** crearemos **monitores** fácilmente y de forma eficiente.

2. Programación multihilo.

La programación multihilo permite llevar a cabo diferentes hilos de ejecución a la vez, es decir, permite realizar diferentes tareas en una aplicación de forma concurrente. La mayoría de lenguajes de programación permiten trabajar con hilos y realizar programación multihilo. También son multihilo la mayoría de las aplicaciones que usamos a nuestros ordenadores (editores de texto, navegadores, editores gráficos...), hecho que nos da la sensación de más agilidad de ejecución.

En un editor de texto, por ejemplo, un hilo puede estar controlando la ortografía del texto, otro puede estar atento a las pulsaciones sobre los iconos de la interfaz gráfica y el otro guardando el documento.

2.1 Los hilos.

La programación tradicional está diseñada para trabajar de forma secuencial, de forma que cuando acaba un proceso se pone en marcha otro. Los hilos son una forma de ejecutar paralelamente diferentes partes de un mismo programa. En Java los hilos son conocidos como threads.

2.1.1 Definición de hilo.

Un hilo o **thread** es la unidad de procesamiento más pequeña que puede ser planificada por un sistema operativo.

El hilos nos permiten ejecutar concurrentemente diferentes tareas con un gasto mínimo de recursos puesto que todos los hilos de un mismo proceso comparten el espacio de memoria y su creación consume poco tiempo de procesador. Son entidades ligeras.

Del mismo modo que un sistema operativo permite ejecutar diferentes procesos a la vez por concurrencia o paralelismo, dentro de un proceso habrá uno o varios hilos en ejecución.

Los hilos representan exclusivamente las ejecuciones de las instrucciones de un programa que se llevan a cabo simultáneamente en el contexto de un mismo proceso. Es decir, compartiendo el acceso en la misma zona de memoria asignada al proceso al que pertenecen. **Cada proceso contiene como mínimo un hilo**, a pesar de que puede llegar a contener muchos.

2.1.2 Relación proceso e hijo.

Recordáis que los procesos no comparten memoria entre ellos, son independientes, llevan información sobre su estado e interactúan con otros procesos a través de mecanismos de comunicación dados por el sistema. Esta comunicación o el cambio de estado de un proceso son mecanismos costosos para el microprocesador. Es por eso que se denominan entidades pesadas. Los hilos, en cambio, comparten recursos. El cambio de estado y de ejecución se realiza mucho más rápidamente y pueden comunicarse entre ellos usando los datos de la memoria que comparten. El tiempo de uso del microprocesador dedicado a la gestión de hilos es bastante despreciable.

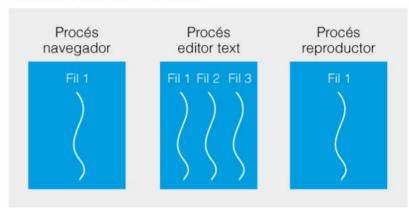
El hecho que los hilos de ejecución de un mismo proceso compartan los recursos hace que cualquier hilo pueda modificarlos. Si un hilo modifica un dato en la memoria, el resto de los hilos tienen acceso al nuevo dato de forma inmediata. Cuando hay un proceso ejecutándose, como mínimo siempre hay un hilo en ejecución. Hablamos de procesos multihilo cuando se ejecutan varios hilos concurrentemente, realizando diferentes tareas y colaborando entre ellos.

Cuando un proceso finaliza, todos sus hilos también lo hacen. De forma equivalente, cuando finalizan todos los hilos de un proceso, el proceso también acaba y todos sus recursos son liberados.

Los sistemas operativos actuales admiten la concurrencia, es decir, pueden ejecutar diferentes procesos a la vez. Podemos estar navegando por Internet con un navegador, escuchando música con un reproductor y, con un editor de texto, redactando un documento. Cada aplicación que se ejecuta es un proceso y cada uno de estos procesos tiene como mínimo un hilo de ejecución, pero podrían tener más de uno. El editor de texto podría tener un hilo que se encargara de ver qué tecla estamos picando, otro que vaya comprobando la ortografía y otro que de vez en cuando se active para guardar el documento. Hay que ver que un hilo pertenece a un proceso y que los diferentes hilos pueden hacer tareas diferentes dentro de su proceso.

En la figura 2.1 vemos un símil de los tres procesos anteriores con sus hilos de ejecución.

FIGURA 2.1. Diferents processos amb fils

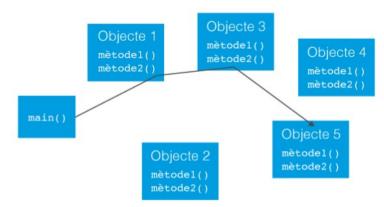


2.1.3 Los hilos en Java.

Cuando empezamos un programa en Java hay un hilo en ejecución, el hilo principal, que es creado por el método main(). Este hilo es importante puesto que es el encargado, si hace falta, de crear el resto de hilos del programa. Se tiene que programar la aplicación con el objetivo de que el hilo principal sea el último al acabar su ejecución. Esto se consigue haciendo esperar los hilos creados por el hilo principal a que este último finalice.

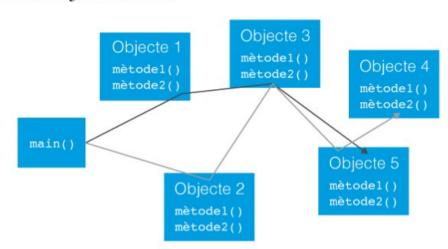
Si no se crean más hilos que el principal, solo existe uno y será el encargado de hacer los llamamientos en los métodos y crear los objetos que indique el programa. En la figura 2.2 podemos ver cómo el hilo principal va ejecutando secuencialmente los métodos de los diferentes objetos que el programa le va indicando.

FIGURA 2.2. Un únic fil d'execució



En la figura 2.3 vemos como, desde el hilo principal, se crea otro hilo que va siguiendo un orden de ejecución diferente de la ejecución del principal y como, en un momento dado, ejecutan de forma simultánea el mismo método del mismo objeto.

FIGURA 2.3. Dos fils d'execució



Java define la funcionalidad principal de la gestión de los hilos a la clase **Thread**. Gracias a la clase **Thread** podemos crear y ejecutar nuevos hilos, pararlos, retomar la ejecución, esperar la finalización de los hilos creados, etc. La funcionalidad de **Thread** se complementa con la funcionalidad específica de la clase **Object** destinada a resolver la sincronización entre hilos. La sincronización se encapsula dentro de la clase **Object** para que cualquier ejecución disponga siempre de los métodos y mecanismos necesarios para llevarla a cabo.

La herencia nos permitirá, de forma fácil, incorporar la funcionalidad de la clase **Thread** a nuestras implementaciones. Aun así, a causa de que Java no soporta lo herencia múltiple, el lenguaje Java nos ofrece una forma alternativa de incorporar la funcionalidad de **Thread** a nuestras implementaciones usando la interfaz **Runnable**. Vemos la especificación de los principales constructores y métodos de esta clase.

La clase Thread

Constructores:

- Thread(): reserva memoria para crear un objeto Thread.
- Thread(Runnable target): reserva memoria para la creación de un nuevo objeto de la clase Thread el cual gestionará la ejecución del objeto Runnable pasado por parámetro.
- Thread(Runnable target, String name): reserva memoria para la creación de un nuevo objeto de la clase Thread el cual gestionará la ejecución del objeto Runnable pasado por parámetro. El objeto creado se podrá identificar con el nombre pasado en el segundo parámetro.
- Thread(String name) : reserva memoria para crear un objeto Thread identificado con el nombre pasado por parámetro.
- Thread(ThreadGroup group, Runnable target): reserva memoria para un nuevo objeto Thread que gestionará la ejecución del objeto Runnable (target) y que pertenece al grupo de hilos (group).
- Thread(ThreadGroup group, Runnable target, String name): reserva memoria para un nuevo objeto Thread identificado con el nombre name, que pertenece al grupo de hilos (group) y que gestionará la ejecución del objeto Runnable target.
- Thread(ThreadGroup group, String name): crea un nuevo objeto Thread identificado por name y que pertenece al grupo de hilos concreto (group)

Métodos más importantes:

- static Thread currentThread(): nos devuelve el hilo que se está ejecutando.
- string getName(): devuelve el nombre del hilo.
- void setName(String nombre): asigna un nombre al hilo.
- int getPriority(): nos dice la prioridad de ejecución del hilo.
- void setPriority(int Prioridad): asigna la prioridad de ejecución del hilo.
- ThreadGroup getThreadGroup(): devuelve el grupo de hilos al cual pertenece el hilo.
- boolean isAlive(): mira si el hilo está activo. Es decir, si ha habido un llamamiento inicial a su método start() y todavía no ha finalizado la ejecución.
- boolean isDaemon(): nos indica si el hilo es un demonio o no.
- void setDaemon(boolean on): indica si el hilo será un demonio o un hilo de usuario. Los demonios están ligados a su creador, si su creador acaba su eiecución. los hiios demonios también finalizan.
- **void join()** : detiene la ejecución del hilo que hace la llamada y espera la finalización del hilo invocado.
- void join(long Millis): espera la finalización del hilo invocado, pero una vez pasado el tiempo del parámetro (expresado en milisegundos), se continuará la ejecución.
- **void run()** : Representa el inicio de ejecución del hilo. Esta ejecución empieza inmediatamente después de haber llamado al método **start()** .
- static void sleep(long Millis): detiene el hilo invocado, durante el número de milisegundos indicados en el parámetro.
- void start(): pone un hilo en estado preparado para ejecutarse.
- static void yield(): hace que el hilo que se está ejecutando pase al estado de preparado. Sale del procesador.
- static void sleep(long Millis): hace que un hilo que se está ejecutando se duerma durante un tiempo (cesa temporalmente su ejecución), que se establece en milisegundos. El hilo no pierde ninguna propiedad de bloqueo (el hilo no pierde la propiedad de ningún monitor).
- **String toString()**: devuelve una cadena que representa el hilo: nombre, prioridad y su grupo.

Podéis encontrar más información sobre métodos, propiedades y constructores de la clase **Thread** en:

http://docs.oracle.com/javase/6/docs/api/java/lang/Thread.html

https://docs.oracle.com/en/java/javase/11/docs/api/java.base/java/lang/Thread.html

La interfaz Runnable

En el lenguaje Java, tener que heredar de la clase **Thread** para crear clases con esta funcionalidad comporta un problema no menor, puesto que Java no soporta la herencia múltiple y por tanto nos resultará imposible hacer que la nueva clase extienda de ninguna otra que no sea **Thread**. Es decir, nos quedará muy limitada la implementación de clases hilo, usando herencia. Para evitar esta limitación podemos usar la Interfaz **Runnable**. La interfaz **Runnable** fuerza la existencia del método **run** pero no limita la herencia. De hecho los objetos **Runnable** no tienen la capacidad de ejecutarse como un hilo independiente. Por eso hay que usar un objeto **Thread** para gestionar su ejecución.

La clase Object

La clase Object es muy extensa. Aquí únicamente nos centraremos en los métodos que nos proporciona, relacionados con los hilos. Son métodos que nos permiten la comunicación y manipulación de hilos. Esta clase, jerárquicamente, se encuentra a la parte superior de todas las clases de Java, por lo tanto cada clase de Java hereda su funcionalidad. Cada nueva clase, pues, incluye los métodos siguientes:

- wait(): este método hace que un hilo en ejecución pase a un estado de espera hasta que se le notifique que puede continuar la ejecución.
- notify(): es el método encargado de notificar a un hilo que se encuentra en espera que puede continuar la ejecución.
- notifyAll(): funciona de forma similar a notify(), pero notifica que pueden continuar la ejecución todos los hilos en espera.

Estos métodos son utilizados cuando ejecutamos la programación concurrente de diferentes hilos (programación multihilo), y sirven para hacer esperar un hilo a que otro acabe de hacer alguna tarea. También para que, una vez acabada esta tarea, notifique al hilo en espera que puede continuar su ejecución. Estos métodos únicamente pueden ser llamados dentro de métodos sincronizados o dentro de bloques de código sincronizados:

```
synchronized public void metodeSincronitzat(){
    }

public void metode(){
    synchronized (this) {
    }
}
```

2.2 Gestión de hilos.

Cuando un hilo es lanzado tendríamos que poder controlar su comportamiento para comprobar que nuestra aplicación hace lo que tendría que hacer. Es cierto que no tenemos el control total sobre la forma en que se ejecuten el hilos, pero sí que podemos controlar muchas cosas. Tenemos que conocer como se comporta un hilo, comprender su ciclo de vida, para, a continuación, ver cuáles son las posibilidades de control que tenemos sobre ellos.

2.2.1 Creación y ejecución de hilos.

Existen dos formas de creación de hilos en Java:

- Heredando la clase Thread.
- Implementando la interfaz Runnable.

Si queremos crear una clase en la cual sus instancias sean hilos, tendremos que heredar la clase Thread. Esta tiene un método llamado run() (public void run()) que tendremos que sobrescribir para codificar las instrucciones a procesar durante la ejecución del hilo. Podríamos decir que el método run() es para un hilo, lo que es el método main() por un programa.

La ejecución del método **run** no garantiza una ejecución en un hilo independiente. Si queremos invocar el procesamiento de un hilo habrá que gritar el método **start()**. Su invocación iniciará la ejecución de un nuevo hilo justo en la primera instrucción del método**run()**. Es decir el llamamiento de **start** implica la invocación posterior del método **run**.

Ejemplo HeretaFil.java

Puesto que Java no soporta la herencia múltiple, si queremos crear hilos en los cuales la nuestro clase herede de alguna otra clase, se tendrá que utilizar la interfaz **Runnable**. La clase **Thread** contiene un constructor que nos permite pasarle como parámetro cualquier objeto que implemente la interfaz **Runnable**: **Thread** (**Runnable** un**Fil**).

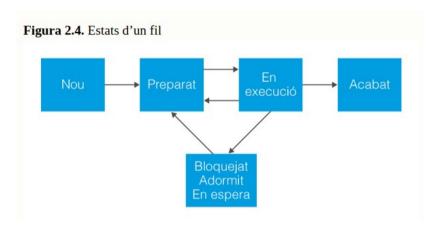
Ejemplo RunnableFil.java

Podemos utilizar la extensión de la clase **Thread** o bien una implementación de la interfaz **Runnable** indistintamente para crear hilos. Heredar de la clase **Thread** limita las posibilidades de nuestra clase a no poder heredar de otra clase en caso de que lo necesitemos. En cambio, implementar la interfaz **Runnable** puede ser algo más complejo, pero nos permite heredar de otra clase y copiar su comportamiento. Es la opción más utilizada por los programadores para crear hilos.

Es posible, pero, que el programa principal (el hilo principal) finalice la ejecución antes de que los hilos creados por él. Para evitar esto, podemos utilizar un método de la clase thread, sleep() que deja el hilo en estado de suspenso durante un cierto tiempo. O también utilizar el método join() que permite hacer que el hilo padre espere que el hilos hijos acaben.

2.2.2 Estados y cambios de estado de un hilo.

El ciclo de vida de un hilo contempla diferentes estados por los que puede ir pasando durante su ejecución (figura.4).



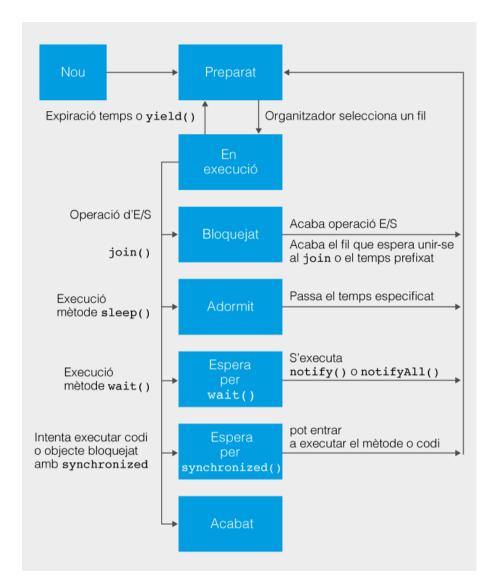
Nuevo es el estado en que se encuentra un hilo cuando ha sido creado con el método **new()**. El método **start()** pone el hilo en estado de **preparado**. Todavía no está en ejecución, si no que está preparado para utilizar el procesador si el organizador de hilos lo encuentra oportuno. Si el organizador le indica que pasa a hacer uso del procesador, entra en el estado de **ejecución**. Del estado de ejecución puede pasar en un estado de **bloqueado**, **dormido** o **en espera** por diferentes motivos. En estos estados un hilo no se ejecuta ni se encuentra a la cola de los hilos en espera de ejecución. Cuando algún acontecimiento lo desbloquee o llegue la hora de despertarse, el hilo transitará del estado de preparado para volver a ser ejecutado. Diremos que un hilo está vivo (**alive**), mientras transita entre los estados preparado, en ejecución, bloqueado, dormido o en espera.

Cuando un hilo finalice su ejecución llegando al final del método **run**, pasará al estado de **finalizado** y diremos que está muerto (dead), porque desde este estado no podrá volverse a ejecutar más. Así pues, la invocación del método **start** de un hilo acabado, provocará una excepción en tiempo de ejecución. La finalización de un hilo no implica que el objeto **Thread** desaparezca y libere la memoria. Las instancias de Thread siguen las mismas reglas que cualquier otro objeto, mientras se encuentren asignadas a alguna variable, se mantendrán en memoria. Podemos forzar la liberación de memoria asignando un valor null a la variable que mantenía el objeto **Thread**, una vez este haya finalizado.

Mientras el hilo está en ejecución, podrá salir por varios motivos:

- Ha expirado el tiempo de uso del procesar por parte del hilo o se ejecuta el método yield().
- Inicia una operación de entrada/salida y pasa a un estado de bloqueado hasta que la operación acabe.
- Llamada al método join() de otro hilo para esperar la finalización del mismo, El hilo invocador pasa al estado de bloqueado hasta que el hilo invocado pase al estado finalizado.
- Intenta ejecutar un código que está sincronizado (synchronized) y no puede porque hay otro hilo ejecutándolo; pasa en un estado de bloqueado hasta que el bloque sincronizado quede liberado.
- Se llama al método wait() pasándolo al estado de espera. Cuando un hilo entra en estado de espera, solo podrá salir si se invoca algún de sus métodos notify() o notifyAll().
- Se invoca el método sleep. El hilo pasa a estado dormido hasta que haya transcurrido el tiempo indicado como parámetro. El estado dormido, es muy útil para mantener un hilo parado durante un tiempo determinado minimizando al máximo los recursos utilizados. Suponemos que un programa de tratamiento de textos, dispone de un hilo que guarda los documentos automáticamente cada 10 minutos.

La figura.5 resume todos los cambios y transacciones que son posibles en los estados de un hilo.



La clase **Thread** contiene el método **isAlive()** que nos indica si un hilo ha sido inicializado (con el método **start()**). Si **isAlive()** devuelve **false**, sabemos que el hilo está en el estado de **nuevo** o **finalizado**, no siendo posible diferenciar estos dos estados. En cambio si devuelve **true** nos dice que el hilo ha sido inicializado con **start()** y se encuentra en cualquier de los otros estados.

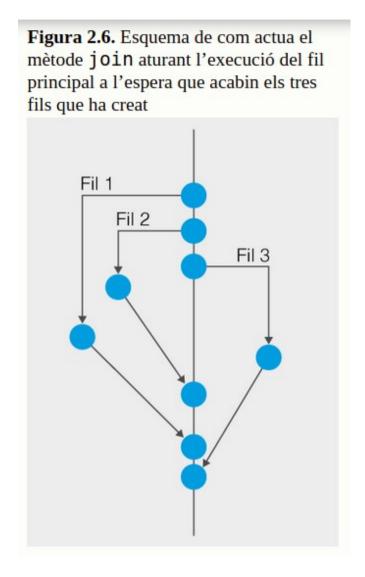
2.2.3 Método thread.join()

La clase **Thread** contiene el método no estático **join()** que permite que un hilo de ejecución espere a otro. Dicho de otro modo, la clase **Thread** permite, a través del método **join()**, que un hilo se una al final de su ejecución a otro hilo.

Si tenemos un hilo A que no puede completar su trabajo hasta que otro hilo B haya acabado, lo que se tiene que hacer es que el hilo A se una al hilo B. El hilo A estará en estado de **bloqueado** hasta que el hilo B haya acabado su ejecución y esté en estado **finalizado** (dead). Lo que hará **hilo.join()** es esperar en estado de bloqueado, hasta que el hilo que lo ha invocado acabe. En caso de que el hilo que lo ha invocado ya haya acabado ignora la orden.

También es utilizado para unir el hilos de ejecución de una aplicación para evitar que el hilo principal acabe antes de que los hilos creados en el código de la aplicación.

En la figura 2.6 se ve como desde un hilo (el hilo principal) se crean 3 hilos que ejecutan sus funciones (tirar un dado) y se esperan a que el hilo que lo ha invocado acabe (el hilo principal).



La figura corresponde al siguiente código, que crea tres hilos y cada uno tira un dado. El programa principal tiene que mostrar el resultado de la suma de las tres tiradas.

Ejemplo JoinFils.java

2.3 Sincronitzación de hilos.

En entornos multihilos que se ejecutan concurrenmente es habitual que entre los diferentes hilos de ejecución haya la necesidad de compartir datos. Esta compartición de datos nos puede servir para comunicar hilos. Utilizaremos variables compartidas para indicar que un hilo ha acabado una cierta función o no y, por lo tanto, otro hilo podrá ejecutar la parte de código que estaba bloqueado por esta variable. También podemos compartir datos de un objeto común. Varios hilos tienen que modificar una propiedad de un objeto. En ambos casos, conviene sincronizar el acceso a los recursos compartidos para evitar inconsistencia de datos o interferencias. Cualquier variable accesible puede ser manipulada por un hilo o el hilo principal. Si este acceso no se controla puede provocar situaciones no esperadas o erróneas.

Trabajando con hilos esta compartición de variables es muy fácil y nada costosa, puesto que los hilos de un mismo proceso comparten el mismo espacio de memoria.

Java proporciona mecanismos para sincronizar los hilos que tratan estos problemas.

Cuando más de un hilo tiene que acceder al mismo recurso es cuando aparece la posibilidad de operaciones que se ejecuten concurrentemente utilizando el mismo objeto o recurso y, por lo tanto, se pueden dar casos de datos corruptos o resultados no esperados. Estas zonas de código que acceden a un recurso compartido y que no pueden ser accesibles al mismo tiempo por más de un hilo, se denominan secciones críticas. Un efecto equivalente es cuando varios hilos quieren ejecutar el código de una sección crítica. Los hilos cooperan utilizando el protocolo que, para realizar algunas operaciones sobre un objeto, tienen que coger el bloqueo del objeto. Coger el bloqueo de un objeto significa que no deja que otros hilos cojan este bloqueo hasta que el hilo que lo tiene lo libere. Esto se denomina exclusión mutua. Si esta acción se realiza correctamente, el hilos de ejecución no realizarán operaciones que interfieran entre sí.

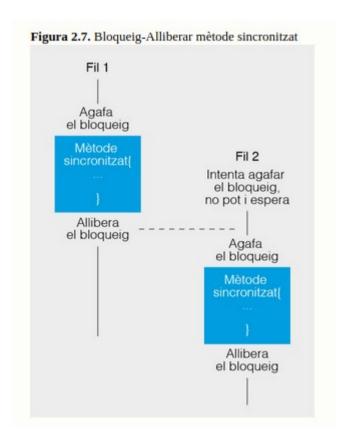
Aquello que se intenta es que las operaciones sobre las secciones críticas sean atómicas. Que se ejecuten totalmente o no se ejecuten.

Por defecto, en Java un objeto no está protegido. Esto quiere decir que cualquier número de hilos puede ejecutar código dentro del objeto. La exclusión mutua se consigue en Java con la palabra reservada synchronized. Esta palabra puede ser aplicada a bloques de código dentro de un método y también a métodos enteros.

2.3.1 Métodos synchronized.

Si queremos proteger los objetos de una clase de posibles interferencias a un entorno multihilo, es decir, que los métodos de esta clase se ejecuten en **exclusión mutua**, tendremos que utilizar el modificador **synchronized** a los métodos que formen parte de la **sección crítica**. El modificador **synchronized** nos garantiza que ningún otro método sincronizado del objeto podrá ejecutarse. Cuando un hilo ejecuta un método sincronizado coge el bloqueo del objeto hasta que acaba su ejecución y se libera del bloqueo. Si otro hilo llama al método sincronizado del mismo objeto, queda bloqueado hasta que quede el hilo que lo está ejecutando lo libere del bloqueo.

En la figura.7 se muestra como dos hilos intentan ejecutar un método sincronizado. Uno toma el bloqueo y el otro se queda a la espera de que lo libere para poder ejecutar el método.



Los métodos sincronizados proporcionan **exclusión mutua** para acceder al recurso compartido. Los métodos no sincronizados del mismo objeto pueden ser ejecutados por varios hilos a la vez. La posesión del bloqueo de un método es única por hilo. Es decir, un hilo no puede bloquear dos veces el mismo método, pero sí que puede hacer llamamientos recursivos a un método bloqueado por él. La forma natural de liberar un bloqueo es que el hilo llegue al **final del código** del método o encuentre una sentencia **return**. También puede liberarlo por otros motivos, como por ejemplo que se lance una **excepción**.

Este sistema que nos proporciona Java de exclusión mutua hace que el programador no tenga que recordar de utilizar *bloqueo* y *liberar bloqueo* en cada método. Java ya lo hace por nosotros.

Aquellos metodos que queremos que se ejecuten en **exclusión mutua** los sincronicemos con la palabra reservada **synchronized**.

Ejemplo: AgenciaViatges.java

Imaginamos una agencia de viajes que venden billetes de avión. Hay dos personas interesadas al viajar con su familia a Roma al vuelo SP233 a las 20.00h. El primero que tendría que hacer el sistema es mirar si hay plazas suficientes al vuelo y si hay, descontar las plazas del avión y asignarlas al cliente.

¿Qué pasaría si las dos personas quieren hacer la reserva al mismo tiempo?

En el main de la clase AgenciaViatges se crean dos hilos sobre la misma instancia del objecto. Cuando se ejecutan al método run(), los dos clientes intentan hacer la reserva de 3 asientos por su familia de forma simultánea. Inicialmente solo hay 5 asientos libres.

En el método run se llama al método **gestioSeientsLliures(3)**. Este método lo que hará será: si hay tres asientos libres los asigna al cliente (es decir, los resta de los asientos libres).

Si hay asientos libres se ejecuta un **sleep()** de 1 segundo, que hará dormir el hilo para simular un sistema más real con más volumen de datos.

El método **sleep(milisegundos)** deja el hilo en estado de **bloqueado** durante un tiempo marcado en milisegundos y una vez pasado este tiempo vuelve al estado de **preparado**. **Durante este tiempo si el hilo tenía el bloqueo de un objeto, lo continuará teniendo**. No pierde el bloqueo durante este tiempo.

Después de despertar el hilo, llama al método **reservaSeients()** de la clase **SeientsAvio** que restará los asientos reservados de los asientos libres.

La solución a este problema es utilizar **semáforos** sobre las secciones críticas. Las secciones críticas en este ejemplo son la consulta de asientos libres y la resta de asientos reservados. Es decir, las operaciones de **gestioSeientsAvio()**.

Un semáforo es como una candado con una única clave. Esta clave únicamente la tendrá el cliente que lo coge primero y ningún otro cliente puede cogerla hasta que él la deje

Java puede crear semáforos con la palabra clave **synchronized**. Utilizaremos el candado en el método encargado de hacer toda la gestión de consulta y reserva de asientos, es decir, al método **gestioSeientsAvio()**. De este modo podremos estar seguros que cuando un cliente toma la clave del candado ningún otro cliente puede hacer esta gestión.

2.3.2 Objectos synchronized.

}

Cuando sincronizamos métodos estamos bloqueando estos métodos para que únicamente un hilo pueda ejecutarlos a la vez. Pero si sincronizamos mucho, todas las ventajas que nos proporciona la concurrencia se pierden. Por lo tanto, tenemos que sincronizar únicamente aquel código que nos interesa. Con Java podemos sincronizar solo una parte de código dentro de un método, aquella parte que queremos que se ejecute en exclusión mutua. Para sincronizar únicamente una parte del código necesitamos hacer referencia a un objeto. El siguiente código muestra como se sincroniza una parte del código sobre el objeto que ha llamado al método metodeNoSincronitzat().

La parte del código sincronizada hará que se ejecute en **exclusión mutua** con cualquier otro bloque sincronizado del mismo objeto. También se ejecutarán en exclusión mutua los métodos con el modificador **synchronized**.

También podemos sincronizar parte del código sobre un objeto diferente a aquel que ha llamado el método que se está ejecutando. Antes de ejecutar el código que está sincronizado, tenemos que coger el bloqueo del objeto **altreObjecte**. Ningún otro hilo tendrá que tener el bloqueo de este objeto.

2.3.3 Sincronizar métodos estàtics.

Los métodos estáticos también se pueden sincronizar. Puesto que únicamente se protege una copia de los datos estáticos que se manipulan, únicamente se necesita un bloqueo por clase.

Todas las instancias tienen un objeto asociado en **java.lang.Class**. Esta instancia es la que se utiliza para proteger (sincronizar) los métodos estáticos.

Si queremos que un método proteja una clase entera, todos lo objetos creados de una clase, tendremos que sincronizar un método estático.

La sincronización de métodos estáticos es similar a los métodos no estáticos.

```
public static synchronized void metodeSincronitzatEstatic() {
      //...
}
```

2.3.4 Variables volatile.

Las variables primitivas en Java son atómicas en lectura y actualización pero no en operaciones. Por lo tanto, podemos omitir la sincronización si el único que queremos hacer es modificar un valor de una variable primitiva. De este modo aumentamos el rendimiento de la aplicación.

La palabra reservada **volatile** aplicada sobre variables indica que se hará la actualización de forma atómica.

2.3.5 Interbloqueo

Las ventajas de sincronizar métodos en Java son evidentes. No podríamos realizar concurrencia sin este tipo de seguridad y bloqueos. Pero tenemos que ir con cuidado cuando aplicamos estos métodos. En primer lugar, solo tenemos que sincronizar aquellos métodos o bloques de código necesarios, puesto que abusar de la sincronización penaliza el rendimiento de la aplicación. En segundo lugar porque si no sincronizamos correctamente se pueden producir errores. Evidentemente podemos realizar bloqueos sin usar las primitivas que nos proporciona Java, pero la fuente de errores es mayor, puesto que tenemos que recordar de coger el bloqueo y liberarlo, cosa que con synchronized, tal como hemos visto, no es necesaria.

El error más grave que se puede producir cuando se trabaja en programación multihilo relativamente compleja es el llamado **interbloqueo** (en inglés deadlock). El interbloqueo se produce cuando dos hilos se están ejecutando concurrentemente y cada uno tiene un bloqueo exclusivo que el otro necesita para continuar. El fenómeno puede pasar con más de dos hilos y por norma general pasa cuando los hilos cogen los mismos bloqueos en diferente orden.

Imaginamos una aplicación que gestiona los recursos de una entidad bancaria (cuentas bancarias, documentos, etc.) que permitan que los datos puedan ser transferidos de un recurso a otro. Cada recurso tiene un bloqueo asociado para él. Si se quiere hacer una transferencia, el hilo tiene que coger el bloqueo de todos los recursos que intervienen en la transferencia. Si dos hilos inician la transferencia que afecta a dos recursos y los hilos cogen el bloqueo de los recursos en diferente orden, ya tenemos un interbloqueo.

2.4 Compartir información entre hilos.

La palabra clave **synchronized** nos da seguridad e integridad en métodos o partes de código. Pero además de sincronización y protección, los hilos también tienen que poder comunicarse entre ellos. Java nos proporciona métodos que hacen que los hilos esperen y continúen su ejecución. Son los métodos: **wait()**, **notify()** y **notifyAll()**.

2.4.1 Metodos wait(), notify() y notifyAll().

Sincronizar métodos nos proporciona una exclusión mutua para acceder a una sección crítica. Pero si existen hilos interdependientes o un hilo tiene que esperar una condición para poder continuar su ejecución y esta condición lo tiene que dar otro hilo, el sincronismo no lo soluciona.

Imaginamos dos hilos que controlan el envío y el procesamiento de correos electrónicos. El primer hilo está buscando correos electrónicos para poner en la cola de enviados y el que procesa los correos los construye para dejarlos en la cola. Por qué el primer hilo tiene que estar malgastando tiempo y recursos cada dos segundos buscando a la cola de correos para enviar si todavía no hay?. Es mejor si lo ponemos en suspensión y cuando llegue un correo a la cola ya lo avisaremos y verificaremos el correo para enviarlo.

Los métodos que proporciona Java para esperas y notificaciones son:

wait(): saca el hilo en curso y mantiene el bloqueo de la zona de exclusión mutua.
 Lo envía a una cola de espera o conjunto de espera (wait set en inglés) y lo pasa al estado de espera.

Tendrá que esperar en la cola hasta que otro hilo lo saque de allí y lo cambie al estado de **preparado** mediante los métodos **notify()** o **notifyAll()**.

- notify(): un hilo de la cola de espera es seleccionado para pasar al estado de preparado.
- notifyAll(): todos los hilos del la cola de espera pasan al estado de preparado.

Tanto **notify()** como **notifyAll()** posan a preparado los hilos de la cola de espera, si hay. Si no hay ningún hilo esperando, la instrucción es ignorada.

Estos métodos son de la clase **Object**, por lo tanto son heredados por todas las clases de forma implícita.

Los tres métodos, wait(), notify() y notifyAll(), tienen que ejecutarse sobre el hilo que tiene el bloqueo. Por lo tanto, todos los llamamientos a estos métodos se tienen que hacer desde métodos o bloques de código sincronizados.

La utilización de sincronismo y comunicación de hilos en Java es la forma de crear monitores. Recordamos que un monitor es una estructura de alto nivel que gestiona la concurrencia de forma que solo permite a un único hilo coger el monitor (un único hilo tiene acceso a la vez) y contiene una lista de hilos en espera para entrar a gestionar su acceso.

Existe una forma más o menos estándar de implementar los hilos que tienen que esperar que suceda un acontecimiento para poder continuar la ejecución.

El código siguiente muestra de qué manera, si una condición no es cierta, **el hilo pasará al estado en espera y dejará libre el bloqueo sobre el objeto**. Cuando otro hilo le notifique que puede continuar su ejecución y se ejecute, volverá a evaluar la condición y, si es cierta, ejecutará el código. El encargado de notificar que puede continuar y que tiene que salir de la cola de espera es un método que hace que la condición se haga cierta.

Básicamente, un monitor tiene que tener: un método que envíe los hilos a la cola de espera (wait()) dependiendo de una condición; otro método que rescate los hilos de la cola de espera (notify()) y cambie el valor de la condición; y un constructor que inicialice la variable de la condición.

2.4.2 Productor-consumidor

Un ejemplo clásico de programación concurrente y multihilos es el modelo de productorconsumidor. Se trata de un hilo (productor) que genera una salida que es cogida por otro hilo (consumidor).

Imaginamos un sistema en el cual un hilo (productor) va generando números aleatorios y otro hilo (consumidor) los va cogiendo para mostrarlos.

Nos encontramos diferentes clases. La clase monitor será nuestro recipiente de números. habrán dos métodos: agafar() que nos devolverá el número generado por el productor y deixar(int) que dejará el número a disposición del consumidor. Por lo tanto, la clase monitor realizará el control de transacción y comunicación entre los dos hilos: productor y consumidor.

La clase productor se encargará de ir produciendo los números y de dejarlos a disposición del consumidor del monitor.

La clase consumidor se encargará de ir consumiendo los números del monitor.

La clase principal crea dos hilos: un productor y un consumidor y los ejecuta.

Ejemplo: ProductorConsumidor.java

Una cola LIFO es una estructura de datos en forma de cola en la cual el elemento que entra a la estructura en último lugar es lo primero al salir (Last In First Out en inglés). Este tipo de cola también se denomina pila.

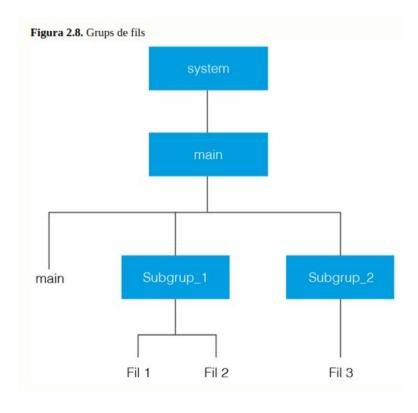
2.5 Agrupación de hilos

En uno en torno a red, un servidor recibe muchas peticiones a la vez: de programas en ejecución, de clientes, cálculos complejas, transacciones de base de datos, etc. Un hilo acostumbra a crear hilos nuevos para atender estas peticiones. Si el número de peticiones es grande, el número de hilos también lo es y la administración de los hilos es complicada. Para simplificar esta administración se crean grupos de hilos. La clase **ThreadGroup** es la que define e implementa todo aquello relacionado con grupos de hilos.

2.5.1 Agrupación por defecto i creación de grupos

Todos los hilos de ejecución en Java pertenecen a un grupo. Los grupos de hilos son un mecanismo que nos permite agrupar hilos en un único objeto y nos permite la manipulación de todos el hilos que pertenecen al grupo como si fuera uno y no de forma individual. Podríamos arrancar o dormir todos los hilos de un grupo, aplicando el método correspondiente al objeto grupo.

En la figura 2.8 podemos ver como existe como mínimo un hilo de ejecución principal creado por el método main y después los diferentes subgrupos creados por la aplicación. Cada grupo tiene un número de hilos. El subgrupo_1 tiene dos hilos (Hilo1 e Hilo2) y el subgrupo 2 un hilo (Hilo3).



La clase **ThreadGroup** nos proporciona dos constructores:

- ThreadGroup(String name)
- ThreadGroup(ThreadGroup parent, String name)

Todos los hilos tienen un grupo y todos los grupos creados en la aplicación tienen un grupo padre. Los dos constructores crean grupos y les dan un nombre. La diferencia es la elección de a qué subgrupo pertenecen.

El primer constructor pertenece al mismo grupo que el hilo que hace le hace la llamada. El segundo constructor indica a qué padre pertenece. Por ejemplo, si el hilo principal hace un llamamiento a **ThreadGroup(String name)**, el nuevo grupo de hilos tiene como grupo padre el **main**.

El ejemplo siguiente muestra como se utilizan los dos constructores. Se crea un subgrupo en el grupo padre main con el nombre **subGrup_1** y posteriormente se crea otro grupo que tiene como padre el grupo que acabamos de crear:

La creación de grupos de hilos no tiene mucha utilidad si no le asignamos hilos al grupo.

En el siguiente código se muestra como se crea un grupo llamado **subgrupo 2** y posteriormente como se crea un hilo (**Hilo 1**) y lo asignamos al grupo.

```
ThreadGroup sgr = new ThreadGroup ("subgrup 2");
Thread fil = new Thread (sgr, "Fil 1");
```

2.5.2 Clase ThreadGroup

ThreadGroup contiene toda la funcionalidad para la manipulación de grupos de hilos. Un grupo puede tener un número de hilos ilimitado. Habitualmente todos el hilos de un grupo tienen algo en común: quién los creó, qué función tienen o cuándo tienen que ejecutarse o finalizar. En el siguiente código creamos un grupo (**subgrup 1**) que tiene como padre **main**. Después creamos dos hilos y les decimos que pertenecen al grupo creado. Creamos otro grupo (**subgrup 2**) y creamos un hilo (**Fil 3**) que pertenece al nuevo grupo. Es el esquema de la figura 2.8.

El método activeGroupCount() nos dice cuántos grupos hay activos y currentThread().getThreadGroup(), como se llama el grupo del hilo activo. list() es un método que da los detalles del grupo activo y sus subgrupos (nombre, prioridad...)

Ejemplo: GrupsFils.java

La prioridad de un grupo es la prioridad más alta de los hilos que pertenecen al grupo.

Los métodos siguientes de la clase **ThreadGroup** únicamente tienen efecto sobre el grupo, no sobre los hilos del grupo:

- **getMaxPriority**: devuelve la prioridad del grupo.
- setMaxPriority: modifica la prioridad del grupo, no la de los hilos. Por lo tanto, si
 disminuimos la prioridad del grupo, puede ser que haya un hilo con una prioridad
 más alta que el grupo.
- **getDaemon** y **setDaemon**: devuelve si es un grupo demonio y asigna a un grupo de hilos si se comportará como demonio o no.
- getName: devuelve el nombre del grupo.
- getParent: devuelve el padre de un grupo.
- parentOf: nos dice si el grupo de hilo pertenece al grupo que le pasamos por parámetros.
- toString: convierte en string los detalles del grupo (nombre, prioridad, etc).

2.6 Gestión de hilos por parte del sistema operativo.

La máquina virtual de Java (JVM, Java Virtual Machine en inglés) es un sistema multihilo, y es la encargada de gestionar los hilos, de asignar el tiempo de ejecución, las prioridades, etc. Es la encargada de decidir qué hilo entra a ejecutarse. La gestión que hace de los hilos es similar a la que tiene el sistema operativo cuando gestiona más de un proceso. La máquina virtual de Java es un proceso dentro del sistema operativo, es decir, puesto que el hilos se ejecutan a la máquina virtual, comparten recursos.

2.6.1 Planificación de hilos

La manera que tiene el sistema operativo de comportarse con la ejecución de hilos es un tema importante en la programación multihilo. La planificación hace referencia a qué política se tiene que seguir para decidir qué hilo coge el control del procesador y en qué momento. También se tiene que planificar cuando tiene que dejar de ejecutarse. Java está diseñado para que sea un sistema portable. El sistema de hilos tiene que ser soportado por cualquier plataforma y, puesto que cada plataforma funciona de forma diferente, el tratamiento de los hilos tiene que ser muy general. Como características más importantes de la planificación de hilos tenemos:

- Todos los hilos tienen asignada una prioridad y el encargado de decidir qué hilo se ejecuta tiene que garantizar que los hilos con prioridad más alta tengan preferencia. Pero esto no implica que en un momento dado un hilo con prioridad más baja esté ejecutándose.
- Se tiene que garantizar que todos los hilos se ejecuten en algún momento.
- El tiempo asignado a cada hilo para hacer uso del procesador puede aplicarse o no depende del sistema operativo en el cual se ejecuta la máquina virtual.

Con estas premisas el programador tiene que tener en cuenta a la hora de programar que los hilos pueden intercalar su ejecución en cualquier momento. Si queremos una ordenación en la ejecución de hilos, tenemos que añadir código en nuestra programación para que pase.

2.6.2 Prioridad de hilos

Las prioridades de los hilos en Java son inicialmente la misma que los hilos creadores. Por defecto tienen una prioridad de 5. El rango de prioridades va desde 1, definida con la propiedad de **Thread MIN_PRIORITY** a 10 definida por **MAX_PRIORITY**. La prioridad por defecto con valor 5 es **NORM_PRIORITY**.

Los hilos con una prioridad más alta serán puestos en ejecución por parte del planificador en primer lugar y los de prioridad más baja cuando los de prioridad superior estén bloqueados o hayan acabado la ejecución. La clase **Thread** tiene dos métodos que permiten ver y modificar las prioridades de los hilos:

 setPriority() permite modificar la prioridad de un hilo: fil.setPriority(8);

```
    getPriority() vuelve la prioridad de un hilo:

        System.out.println("Prioridad hilo " +

        fil.getPriority());
```

Swing es una API de Java que proporciona la interfaz gráfica de usuario en Java. Es la API que sustituye a la otra API gráfica (**AWT**) que únicamente permite una apariencia gráfica igual al sistema nativo de la plataforma en la cual se ejecuta. En cambio **Swing** también permite una apariencia que no tiene nada que ver con la plataforma nativa.

Los hilos de las clases que generan interfaces de usuario (Swing y AWT) tienen por defecto una prioridad de 6. De este modo la interacción con el usuario es más fluida.

Si no hay ningún acontecimiento de entrada los hilos están a la espera. Así los otros hilos no son perjudicados por ellos. Cuando hay un acontecimiento de entrada por ratón o teclado los hilos responden inmediatamente.

El método **yield()** hace que un hilo que se está ejecutando pase de nuevo al estado y a la cola de **preparados**. De este modo permite que otros hilos de prioridad superior o de la misma prioridad se puedan ejecutar. Pero puede pasar que una vez pasado a preparado vuelva a ser escogido para ejecutarse de nuevo.

En el siguiente código de ejemplo se muestra como creamos dos hilos que competirán por quién acaba primero su ejecución. En condiciones normales, con la misma prioridad, el ganador se iría alternando, dependiendo de qué escogiera el organizador de la cola de hilos. Pero al modificar las prioridades de los hilos, al primero le asignamos la prioridad más baja y al segundo la más alta. De este modo nos aseguramos que siempre gane el segundo. Esto hará que el segundo acapare el procesador hasta que acabe su ejecución.

Los resultados también dependerán del sistema operativo sobre el cual se ejecuta la máquina virtual, puesto que las prioridades pueden variar de un sistema a otro.

Utilizamos el método setName() de la clase Thread para asignarle un nombre a cada hilo.

Ejemplo: PrioritatsFils.java

2.6.3 Hilos demonio

Cuando creamos un hilo y antes de llamar al método **start()** podemos indicar que el hilo será ejecutado como un demonio (daemon en inglés). Esto permitirá al hilo ejecutarse en un segundo plano. Los hilos demonios tienen la prioridad más baja. Si un hilo demonio crea otro hilo, este también será un demonio. Esta calidad se hereda. Y no se puede cambiar una vez el hilo ha sido inicializado. Se encuentra en el estado de preparado.

Garbage collector es un demonio creado por la máquina virtual de Java, que se encarga de liberar memoria ocupada por objetos que no están referenciados.

Para indicar que un hilo es un demonio se utiliza el método **setDaemon(true)**. En el caso de **setDaemon(false)**, el hilo es de usuario, la opción por defecto. Los hilos demonios finalizan cuando finaliza el último hilo de usuario y la aplicación acaba.

```
hilo.setDaemon(true);
```

Para ver si un hilo es un demonio, se utiliza el método isDaemon() que devolverá un booleano indicando si el hilo es un demonio o no.

```
System.out.println(hilo.isDaemon());
```

El siguiente ejemplo muestra como se crea un demonio. Y después como, desde este demonio, se crea un **array** de 10 demonios. Tenemos que ver que los hilos demonios creados por el demonio inicial no los indicamos con **setDaemon(true)**, pero heredan esta calidad del hilo que lo ha creado.

Si quisiéramos crear hilos que no fueran demonio, tendríamos que indicarlo expresamente con **setDaemon(false)**, antes del método **start()** del hilo.

Ejemplo: FilsDimonis.java

2.7 Documentació	n de aplicaciones i	depuración de
aplicaciones multi	hilo	-

2.7.1 Depuración de aplicaciones multihilo